

第二章 线性代数方程组数值解法

哈尔滨工业大学数学学院

<http://homepage.hit.edu.cn/LiuWenjie>



§2.1 引言

对于线性方程组

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases} \quad (1)$$

可以写成矩阵的形式 $A\mathbf{x} = \mathbf{b}$, 其中

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

若系数阵 A 非奇异 $|A| \neq 0$, 则线性方程组有唯一解。只讨论系数矩阵为非奇异的线性方程组。

§2.1 引言

直接解法: 是解线性方程组的重要方法. 它是指通过有限步的算术运算求出精确解的方法 (若计算过程没有舍入误差). 其基本思想是通过等价变换将线性方程组化为结构简单、易于求解的形式, 从而求解.

$$Ax = b \quad \text{初等变换或者矩阵分解方法等} \quad Gx = d$$

迭代法: 的基本思想是用某种极限过程逐次逼近方程组的解的方法, 是解线性方程组的重要方法. 它具有占有储存单元少、程序设计简单、原始系数矩阵在计算过程中不变的优点, 但需考虑收敛性和收敛速度问题.

$$A = M + N, (M + N)x = b, x = -M^{-1}Nx + M^{-1}b$$

给定 $x^{(0)}$ 构造迭代过程

$$x^{(k+1)} = Bx^{(k)} + f, \quad k = 0, 1, 2, \dots$$

其中 $B = -M^{-1}N, f = M^{-1}b$

§2.2 Gauss 消去法

例 用消去法解线性方程组

$$\begin{cases} x_1 + \frac{1}{2}x_2 + \frac{1}{3}x_3 = \frac{11}{6} \\ \frac{1}{2}x_1 + \frac{1}{3}x_2 + \frac{1}{4}x_3 = \frac{13}{12} \\ \frac{1}{3}x_1 + \frac{1}{4}x_2 + \frac{1}{5}x_3 = \frac{47}{60} \end{cases}$$

解

$$\begin{cases} x_1 + \frac{1}{2}x_2 + \frac{1}{3}x_3 = \frac{11}{6} \\ \frac{1}{12}x_2 + \frac{1}{12}x_3 = \frac{1}{6} \\ \frac{1}{12}x_2 + \frac{4}{45}x_3 = \frac{31}{180} \end{cases}$$

§2.2 Gauss 消去法

$$\begin{cases} x_1 + \frac{1}{2}x_2 + \frac{1}{3}x_3 = \frac{11}{6} \\ \frac{1}{12}x_2 + \frac{1}{12}x_3 = \frac{1}{6} \\ \frac{1}{180}x_3 = \frac{1}{180} \end{cases}$$

高斯消去法的主要思路：将系数矩阵 A 化为上三角矩阵，然后回代求解。

高斯消去法是求解线性方程组的经典算法，它在当代数学中有着非常重要的地位和价值，是线性代数的重要组成部分。高斯消去法除了用于线性方程组求解外，还用于计算矩阵行列式、求矩阵的秩、计算矩阵的逆等。

§2.2 Gauss 消去法: 一般形式

Gauss 消去法包括消元过程和回代过程两个环节

(一) 消元过程:

将方程组 (1) 记为 $A^{(1)}x = b^{(1)}$, 其中

$$A^{(1)} = (a_{ij}^{(1)})_{n \times n} = A, \quad b^{(1)} = b$$

第 1 步 消第 1 列 ($k = 1$): 设 $a_{11}^{(1)} \neq 0$, 首先计算乘数

$$m_{i1} = a_{i1}^{(1)} / a_{11}^{(1)}, \quad i = 2, 3, \dots, n$$

用 $-m_{i1}$ 乘方程组(1)的第 1 个方程, 加到第 i 个 ($i = 2, 3, \dots, n$) 方程上, 消去方程组(1) 的从第 2 个方程到第 n 个方程中的未知数 x_1 , 得到与方程组(1)等价的线性方程组

§2.2 Gauss 消去法: 一般形式

原方程

$$\begin{cases} a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + \cdots a_{1n}^{(1)}x_n = b_1^{(1)} \\ a_{21}^{(1)}x_1 + a_{22}^{(1)}x_2 + \cdots a_{2n}^{(1)}x_n = b_2^{(1)} \\ \vdots \\ a_{n1}^{(1)}x_1 + a_{n2}^{(1)}x_2 + \cdots a_{nn}^{(1)}x_n = b_n^{(1)} \end{cases}$$

第一次消元过程后

$$\begin{cases} a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + \cdots + a_{1n}^{(1)}x_n = b_1^{(1)} \\ a_{22}^{(2)}x_2 + \cdots + a_{2n}^{(2)}x_n = b_2^{(2)} \\ \vdots \\ a_{n2}^{(2)}x_2 + \cdots + a_{nn}^{(2)}x_n = b_n^{(2)} \end{cases}$$

§2.2 Gauss 消去法: 一般形式

简记为

$$A^{(2)}x = b^{(2)}$$

其中 $A^{(2)}, b^{(2)}$ 的元素计算公式为

$$\begin{cases} a_{ij}^{(2)} = a_{ij}^{(1)} - m_{i1}a_{1j}^{(1)}, & i, j = 2, 3, \dots, n \\ b_i^{(2)} = b_i^{(1)} - m_{i1}b_1^{(1)}, & i = 2, 3, \dots, n \end{cases}$$

第 k 步 第 k 次消元 ($k = 1, 2, \dots, n-1$), 消第 k 列

设上述第 1 步, ..., 第 $k-1$ 步消元过程讨论一算已经完成, 即已计算好与原方程组等价的线性方程组, 记为

$$A^{(k)}x = b^{(k)}, 1 \leq k \leq n-1$$

其中, $k \geq 2$ 矩阵 $A^{(k)}$ 有下面形式

§2.2 Gauss 消去法: 一般形式

$$A^{(k)} = \begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & \cdots & \cdots & a_{1n}^{(1)} \\ 0 & a_{22}^{(2)} & & & & a_{2n}^{(2)} \\ \vdots & & \ddots & & & \vdots \\ 0 & \cdots & 0 & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} \\ \vdots & & \vdots & \vdots & & \vdots \\ 0 & \cdots & 0 & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} \end{pmatrix}$$

假设 $a_{kk}^{(k)} \neq 0$ 计算乘数

$$m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}, i = k + 1, \dots, n$$

令

$$\begin{aligned} a_{ij}^{(k+1)} &= a_{ij}^{(k)} - m_{ik} a_{kj}^{(k)}, i, j = k + 1, \dots, n \\ b_i^{(k+1)} &= b_i^{(k)} - m_{ik} b_k^{(k)}, i = k + 1, \dots, n \end{aligned}$$

§2.2 Gauss 消去法: 一般形式

得到等价方程组

$$A^{(k+1)}x = b^{(k+1)}, 1 \leq k \leq n-1$$

$A^{(k+1)}$ 中从第 1 行到第 k 行与 $A^{(k)}$ 相同.

一直进行到 $k = n-1$ 得到等价方程组 $A^{(n)}x = b^{(n)}$,

$$\begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ & & \ddots & \vdots \\ & & & a_{nn}^{(n)} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1^{(1)} \\ b_2^{(2)} \\ \vdots \\ b_n^{(n)} \end{pmatrix}$$

(二) 回代求解

$$\begin{cases} x_n = b^{(n)} / a_{nn}^{(n)} \\ x_k = \left(b_k^{(k)} - \sum_{j=k+1}^n a_{kj}^{(k)} x_j \right) / a_{kk}^{(k)}, \quad k = n-1, n-2, \cdots, 1 \end{cases}$$

§2.2 Gauss 消去法: 一般形式

由上面的计算过程可知, Gauss 消去法能顺利进行下去的充要条件是 $a_{kk}^{(k)} \neq 0$, $k = 1, 2, \dots, n$, 这些元素被称为**主元**.

定理

设 $A \in \mathbb{R}^{n \times n}$, 则所有主元 $a_{kk}^{(k)}$ 都不为零的充要条件是 A 的所有顺序主子式都不为零, 即

$$D_1 \triangleq a_{11} \neq 0, \quad D_k \triangleq \begin{vmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \cdots & a_{kk} \end{vmatrix} \neq 0, \quad k = 2, 3, \dots, n.$$

事实上, 如果 A 的所有顺序主子式都不为零, 则主元为

$$a_{11}^{(1)} = D_1, \quad a_{kk}^{(k)} = \frac{D_k}{D_{k-1}}, \quad k = 2, 3, \dots, n.$$

§2.2 Gauss 消去法: 消元过程的计算量

第 k 步乘法/除法运算

$$m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}, \quad i = k + 1, \dots, n$$

需要 $n - k$ 步除法

$$\begin{aligned} a_{ij}^{(k+1)} &= a_{ij}^{(k)} - m_{ik} a_{kj}^{(k)}, \quad i, j = k + 1, \dots, n \\ b_i^{(k+1)} &= b_i^{(k)} - m_{ik} b_k^{(k)}, \quad i = k + 1, \dots, n \end{aligned}$$

需要 $(n - k)(n - k + 1)$ 步乘法, 总的乘法/除法运算步数

$$(n - k) + (n - k)(n - k + 1) = (n - k)(n - k + 2)$$

第 k 步加法/减法运算

$$(n - k)(n - k + 1)$$

§2.2 Gauss 消去法: 消元过程的计算量

$$\sum_{j=1}^m 1 = m, \quad \sum_{j=1}^m j = \frac{m(m+1)}{2}, \quad \sum_{j=1}^m j^2 = \frac{m(m+1)(2m+1)}{6}.$$

乘法/除法运算

$$\begin{aligned} \sum_{k=1}^{n-1} (n-k)(n-k+2) &= \sum_{k=1}^{n-1} (n^2 - 2nk + k^2 + 2n - 2k) \\ &= \sum_{k=1}^{n-1} (n-k)^2 + 2 \sum_{k=1}^{n-1} (n-k) = \sum_{k=1}^{n-1} k^2 + 2 \sum_{k=1}^{n-1} k \\ &= \frac{(n-1)n(2n-1)}{6} + 2 \frac{(n-1)n}{2} \\ &= \frac{2n^3 + 3n^2 - 5n}{6} \end{aligned}$$

§2.2 Gauss 消去法: 消元过程的计算量

加法/减法运算

$$\begin{aligned}\sum_{k=1}^{n-1} (n-k)(n-k+1) &= \sum_{k=1}^{n-1} (n^2 - 2nk + k^2 + n - k) \\ &= \sum_{k=1}^{n-1} (n-k)^2 + \sum_{k=1}^{n-1} (n-k) = \sum_{k=1}^{n-1} k^2 + \sum_{k=1}^{n-1} k \\ &= \frac{(n-1)n(2n-1)}{6} + \frac{(n-1)n}{2} = \frac{n^3 - n}{3}\end{aligned}$$

§2.2 Gauss 消去法: 回代过程的计算量

$$\begin{cases} x_n = b^{(n)} / a_{nn}^{(n)} \\ x_k = \left(b_k^{(k)} - \sum_{j=k+1}^n a_{kj}^{(k)} x_j \right) / a_{kk}^{(k)}, \quad k = n-1, n-2, \dots, 1 \end{cases}$$

乘除法

$$\begin{aligned} 1 + \sum_{k=1}^{n-1} ((n-k) + 1) &= 1 + \left(\sum_{k=1}^{n-1} (n-k) \right) + n - 1 \\ &= n + \sum_{k=1}^{n-1} (n-k) = n + \sum_{k=1}^{n-1} k = \frac{n^2 + n}{2} \end{aligned}$$

加减法

$$\sum_{k=1}^{n-1} ((n-k-1) + 1) = \sum_{k=1}^{n-1} (n-k) = \sum_{k=1}^{n-1} k = \frac{n^2 - n}{2}$$

§2.2 Gauss 消去法: 总的计算量

乘法/除法

$$\frac{2n^3 + 3n^2 - 5n}{6} + \frac{n^2 + n}{2} = \frac{n^3}{3} + n^2 - \frac{n}{3}$$

加法/减法

$$\frac{n^3 - n}{3} + \frac{n^2 - n}{2} = \frac{n^3}{3} + \frac{n^2}{2} - \frac{5n}{6}$$

§2.2 Gauss 消去法: 列主元消去法

Gauss 消去法能够进行到底的条件是各步的主元素 $a_{kk}^{(k)} \neq 0$. 另外即使主元素 $a_{kk}^{(k)}$ 不为零, 但如果主元素的绝对值很小, 用它作除数, 势必造成舍入误差的严重扩散, 以致于方程组的解的精度受到严重影响。

§2.2 Gauss 消去法: 列主元消去法

例如, 设计算机可保证 10 位有效数字, 用消元法解方程

$$\begin{cases} 0.3 \times 10^{-11}x_1 + x_2 = 0.7 \\ x_1 + x_2 = 0.9 \end{cases} \quad (2)$$

经过第一次消元: 第 2 个方程减去第 1 个方程乘以 $m_{21} = a_{21}/a_{11}$ 得

$$\begin{cases} 0.3 \times 10^{-11}x_1 + x_2 = 0.7 \\ a_{22}^{(2)}x_2 = b_2^{(2)} \end{cases} \quad (3)$$

其中

$$a_{22}^{(2)} = a_{22} - a_{21}/a_{11} \times a_{12} = -0.3333333333 \times 10^{12}$$

§2.2 Gauss 消去法: 列主元消去法

$$b_2^{(2)} = b_2^{(1)} - a_{21}/a_{11} \times b_1^{(1)} = -0.2333333333 \times 10^{12}$$

于是, 由(3)解得

$$\begin{cases} x_2 = b_2^{(2)}/a_{22}^{(2)} = 0.7000000000 \\ x_1 = 0.0000000000 \end{cases}$$

而真解为

$$x_1 = 0.2, \quad x_2 = 0.7$$

造成结果失真的主要因素是主元素 a_{11} 太小, 而且在消元过程中作了分母, 为避免这个情况发生, 应在消元之前, 作行交换.

§2.2 Gauss 消去法: 列主元消去法

定义

若 $|a_{r_k k}^{(k)}| = \max_{k \leq i \leq n} |a_{ik}^{(k)}|$, 则称 $|a_{r_k k}^{(k)}|$ 为列主元素. r_k 行为主元素行, 这时可将第 r_k 行与第 k 行进行交换, 使 $|a_{r_k k}^{(k)}|$ 位于交换后的等价方程组的 $a_{kk}^{(k)}$ 位置, 然后再施实消去法, 这种方法称为列主元消去法.

§2.2 Gauss 消去法: 列主元消去法

应用列主元消去法解 (2). 因为 $a_{21} > a_{11}$, 所以先交换第 1 行与第 2 行, 得

$$\begin{cases} x_1 + x_2 = 0.9 \\ 0.3 \times 10^{-11}x_1 + x_2 = 0.7 \end{cases}$$

然后再应用 Gauss 消去法, 得到消元后的方程组为

$$\begin{cases} x_1 + x_2 = 0.9 \\ x_2 = 0.7 \end{cases} \quad (4)$$

利用 (4) 回代求解, 可以得到正确的结果. 即 $x_1 = 0.2, x_2 = 0.7$

§2.2 Gauss 消去法: 列主元消去法

$$A^{(k)}x = b^{(k)}, 1 \leq k \leq n-1$$

其中, $k \geq 2$ 矩阵 $A^{(k)}$ 有下面形式

$$A^{(k)} = \begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & \cdots & \cdots & a_{1n}^{(1)} \\ 0 & a_{22}^{(2)} & & & & a_{2n}^{(2)} \\ \vdots & & \ddots & & & \vdots \\ 0 & \cdots & 0 & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} \\ \vdots & & \vdots & \vdots & & \vdots \\ 0 & \cdots & 0 & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} \end{pmatrix}$$

1、在 $a_{kk}^{(k)}, \dots, a_{nk}^{(k)}$ 中选出绝对值最大者, 即

$$|a_{r_k, k}^{(k)}| = \max_{k \leq i \leq n} |a_{ik}^{(k)}|$$

确定 r_k (行数) .

§2.2 Gauss 消去法: 列主元消去法

2、若 $a_{r_k,k}^{(k)} \neq 0$, 则交换 r_k 行和 k 行元素, 即

$$a_{kj}^{(k)} \leftrightarrow a_{r_k,j}^{(k)} \quad (k \leq j \leq n)$$

$$b_k^{(k)} \leftrightarrow b_{r_k}^{(k)}$$

然后用 Gauss 消元法进行消元.

若系数阵 A 非奇异 $|A| \neq 0$, 则线性方程组有唯一解。

Gauss 消去法不一定能进行到下去, 列主元消去法一定能执行下去。

列主元 Gauss 消去法要多做一些比较运算, 但

(1) 对系数矩阵要求低, 只需非奇异即可;

(2) 比普通 Gauss 消去法更稳定.

列主元 Gauss 消去法是当前求解线性方程组的直接法中的首选算法。

§2.2 Gauss 消去法: 例

利用 Gauss 消去法求解方程组 $Ax = b$, 其中

$$A = \begin{bmatrix} 1 & 2 & 1 & -2 \\ 2 & 5 & 3 & -2 \\ -2 & -2 & 3 & 5 \\ 1 & 2 & 2 & 4 \end{bmatrix}, \quad b = \begin{bmatrix} 4 \\ 7 \\ -1 \\ 0 \end{bmatrix}$$

§2.2 Gauss 消去法: 例

解 1、消元过程用矩阵表示为

$$[\mathbf{A}^{(1)} \quad \mathbf{b}^{(1)}] = \left[\begin{array}{cccc|c} 1 & 2 & 1 & -2 & 4 \\ 2 & 5 & 3 & -2 & 7 \\ -2 & -2 & 3 & 5 & -1 \\ 1 & 2 & 2 & 4 & 0 \end{array} \right]$$

$$\xrightarrow[r_4 - r_1]{\substack{r_2 - 2r_1, r_3 + 2r_1}} \left[\begin{array}{cccc|c} 1 & 2 & 1 & -2 & 4 \\ 0 & 1 & 1 & 2 & -1 \\ 0 & 2 & 5 & 1 & 7 \\ 0 & 0 & 1 & 6 & -4 \end{array} \right] \xrightarrow{r_3 - 2r_2} \left[\begin{array}{cccc|c} 1 & 2 & 1 & -2 & 4 \\ 0 & 1 & 1 & 2 & -1 \\ 0 & 0 & 3 & -3 & 9 \\ 0 & 0 & 1 & 6 & -4 \end{array} \right]$$

$$\xrightarrow{r_4 - \frac{1}{3}r_3} \left[\begin{array}{cccc|c} 1 & 2 & 1 & -2 & 4 \\ 0 & 1 & 1 & 2 & -1 \\ 0 & 0 & 3 & -3 & 9 \\ 0 & 0 & 0 & 7 & -7 \end{array} \right]$$

§2.2 Gauss 消去法: 例

经三步消元后; 原方程组化为同解的上三角形方程组 $A^{(4)}x = b^{(4)}$.

2、回代过程对方程组 $A^{(4)}x = b^{(4)}$. 自下而上按未知元 x_i 的下标逆序逐步回代得原方程组的解为

$$x_4 = -1, x_3 = 2, x_2 = -1, x_1 = 2$$

即

$$x = (2, -1, 2, -1)^T$$

§2.2 Gauss 消去法: 例

例 用选列主元素的 Gauss 法解下列方程组

$$\begin{bmatrix} 12 & -3 & 3 & 4 \\ -18 & 3 & -1 & -1 \\ 1 & 1 & 1 & 1 \\ 3 & 1 & -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 15 \\ -15 \\ 6 \\ 2 \end{bmatrix}$$

解 消元过程用矩阵表示为

§2.2 Gauss 消去法: 例

$$\left[\begin{array}{cccc|c} 12 & -3 & 3 & 4 & 15 \\ \boxed{-18} & 3 & -1 & -1 & -15 \\ 1 & 1 & 1 & 1 & 6 \\ 3 & 1 & -1 & 1 & 2 \end{array} \right] \xrightarrow{r_2 \leftrightarrow r_1} \left[\begin{array}{cccc|c} -18 & 3 & -1 & -1 & -15 \\ 12 & -3 & 3 & 4 & 15 \\ 1 & 1 & 1 & 1 & 6 \\ 3 & 1 & -1 & 1 & 2 \end{array} \right]$$
$$\xrightarrow[r_4 + \frac{1}{6}r_1]{r_2 + \frac{2}{3}r_1, r_3 + \frac{1}{18}r_1} \left[\begin{array}{cccc|c} -18 & 3 & -1 & -1 & -15 \\ 0 & -1 & \frac{7}{3} & \frac{10}{3} & 5 \\ 0 & \frac{7}{6} & \frac{17}{18} & \frac{17}{18} & \frac{31}{6} \\ 0 & \boxed{\frac{3}{2}} & -\frac{7}{6} & \frac{5}{6} & -\frac{1}{2} \end{array} \right]$$

§2.2 Gauss 消去法: 例

$$\begin{array}{l} \xrightarrow{r_4 \leftrightarrow r_2} \left[\begin{array}{cccc|c} -18 & 3 & -1 & -1 & -15 \\ 0 & \frac{3}{2} & -\frac{7}{6} & \frac{5}{6} & -\frac{1}{2} \\ 0 & \frac{7}{6} & \frac{17}{6} & \frac{17}{18} & \frac{31}{6} \\ 0 & -1 & \frac{7}{3} & \frac{10}{3} & 5 \end{array} \right] \\ \\ \xrightarrow[r_4 + \frac{2}{3}r_2]{r_3 + (-\frac{7}{9})r_2} \left[\begin{array}{cccc|c} -18 & 3 & -1 & -1 & -15 \\ 0 & \frac{3}{2} & -\frac{7}{6} & \frac{5}{6} & -\frac{1}{2} \\ 0 & 0 & \boxed{\frac{50}{27}} & \frac{8}{27} & \frac{50}{9} \\ 0 & 0 & \frac{14}{9} & \frac{35}{9} & \frac{14}{3} \end{array} \right] \\ \\ \xrightarrow{r_4 + (-\frac{21}{25})r_3} \left[\begin{array}{cccc|c} -18 & 3 & -1 & -1 & -15 \\ 0 & \frac{3}{2} & -\frac{7}{6} & \frac{5}{6} & -\frac{1}{2} \\ 0 & 0 & \frac{50}{27} & \frac{8}{27} & \frac{50}{9} \\ 0 & 0 & 0 & \frac{91}{25} & 0 \end{array} \right] \end{array}$$

§2.2 Gauss 消去法: 例

得同解上三角方程组

$$\begin{cases} -18x_1 + 3x_2 - x_3 - x_4 = -15 \\ \frac{3}{2}x_2 - \frac{7}{6}x_3 + \frac{5}{6}x_4 = -\frac{1}{2} \\ \frac{50}{27}x_3 + \frac{8}{27}x_4 = \frac{50}{9} \\ \frac{91}{25}x_4 = 0 \end{cases}$$

回代求解得 $x_4 = 0, x_3 = 3, x_2 = 2, x_1 = 1$, 即 $\mathbf{x} = (1, 2, 3, 0)^T$.

§2.3.1 矩阵三角分解法:Doolittle 分解法

在 Gauss 消元法中, 令 $A^{(1)} = A$. 第一次消元时, 相当于用矩阵

$$L_1 = \begin{bmatrix} 1 & & & & \\ -l_{21} & 1 & & & \\ -l_{31} & 0 & 1 & & \\ \vdots & \vdots & \vdots & \ddots & \\ -l_{n1} & 0 & 0 & \cdots & 1 \end{bmatrix}$$

左乘 $A^{(1)}$, 其中

$$l_{i1} = m_{i1} = \frac{a_{i1}}{a_{11}} \quad (i = 2, 3, \cdots, n)$$

即

$$A^{(2)} = L_1 A^{(1)}, \quad b^{(2)} = L_1 b^{(1)}$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

同样在第 k 次消元时有

$$\mathbf{A}^{(k+1)} = \mathbf{L}_k \mathbf{A}^{(k)}, \quad \mathbf{b}^{(k+1)} = \mathbf{L}_k \mathbf{b}^{(k)}$$

$$\mathbf{L}_k = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -l_{k+1,k} & & \\ & & \vdots & \ddots & \\ & & -l_{nk} & \cdots & 1 \end{bmatrix}$$

其中

$$l_{ik} = m_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}, \quad i = k+1, \dots, n$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

以上过程重复进行 $n - 1$ 次后, 得到 $A^{(n)}$. 记 $U = A^{(n)}$, 显然 U 的下三角部分元素均已化为零, U 即是一个上三角阵.

$$L_{n-1}L_{n-2}\cdots L_2L_1A = U$$

$$L_{n-1}L_{n-2}\cdots L_2L_1b = b^{(n)}$$

$$A = L_1^{-1}L_2^{-1}\cdots L_{n-2}^{-1}L_{n-1}^{-1}U$$

$$L = L_1^{-1}L_2^{-1}\cdots L_{n-2}^{-1}L_{n-1}^{-1}$$

$$A = LU$$

引理

$$L_k^{-1} = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & m_{k+1,k} & & \\ & & \vdots & \ddots & \\ & & m_{nk} & \cdots & 1 \end{bmatrix}$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

引理

$$L_1^{-1} \cdots L_{n-1}^{-1} = \begin{bmatrix} 1 & & & & \\ m_{21} & 1 & & & \\ m_{31} & m_{32} & 1 & & \\ m_{41} & m_{42} & m_{4,3} & 1 & \\ \vdots & \vdots & \vdots & & \ddots \\ m_{n1} & m_{n2} & m_{n3} & \cdots & m_{n,n-1} \end{bmatrix}$$

定理 如果 A 的所有顺序主子式均不为零, 则 A 可分解为 $A = LU$ 其中 L 为单位下三角阵, U 为上三角阵, 且这种分解是**唯一的**.

$$\text{求解 } Ax = b \Leftrightarrow \text{求解 } \begin{cases} Ly = b \\ Ux = y \end{cases}$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

i) 分解 $A = LU$, 其中 L 为单位下三角阵, U 为上三角阵. 即

$$\begin{aligned} A &= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 & \cdots & 0 \\ l_{21} & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \cdots & 1 \end{pmatrix} \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u_{nn} \end{pmatrix} = LU \end{aligned}$$

利用矩阵运算比较两边得其分解公式:

$$u_{1i} = a_{1i}, \quad i = 1, 2, \dots, n$$

$$l_{i1} = a_{i1}/u_{11}, \quad i = 2, \dots, n$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

假设 L 的前 $k-1$ 列和 U 的前 $k-1$ 行都已经得到, 下面计算 L 的第 k 列和 U 的第 k 行

$$a_{ij} = \sum_{r=1}^n l_{ir}u_{rj} = \sum_{r=1}^{\min(i,j)} l_{ir}u_{rj},$$

这里使用了下面条件

$$l_{ir} = 0 \quad i < r; \quad u_{rj} = 0 \quad j < r.$$

由于 $l_{kk} = 1$, 得

$$a_{kj} = \sum_{r=1}^{k-1} l_{kr}u_{rj} + u_{kj}, \quad j = k, \dots, n,$$
$$a_{ik} = \sum_{r=1}^{k-1} l_{ir}u_{rk} + l_{ik}u_{kk}, \quad i = k+1, \dots, n.$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

对 $k = 2, 3, \dots, n$,

$$\begin{cases} u_{kj} = a_{kj} - \sum_{r=1}^{k-1} l_{kr} u_{rj}, & j = k, k+1, \dots, n, \\ l_{ik} = (a_{ik} - \sum_{r=1}^{k-1} l_{ir} u_{rk}) / u_{kk}, & i = k+1, k+2, \dots, n, \quad k \neq n, \end{cases}$$

ii) 求解方程组 $Ly = b$, 即

$$\begin{pmatrix} 1 & 0 & \cdots & 0 \\ l_{21} & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \cdots & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

其计算公式为

$$y_1 = b_1,$$

$$y_k = b_k - \sum_{r=1}^{k-1} l_{kr} y_r, \quad k = 2, 3, \dots, n.$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

iii) 求解方程组 $Ux = y$, 即

$$\begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

其计算公式为

$$x_n = y_n / u_{nn},$$
$$x_k = \left(y_k - \sum_{r=k+1}^n u_{kr} x_r \right) / u_{kk} \quad k = n-1, n-2, \cdots, 1.$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

观察发现

- 当 A 的第 i 列被用于计算 L 的第 i 列后, 后面的计算中不再被使用
 - 同样, A 的第 i 行被用于计算 U 的第 i 行后, 后面的计算中也不再使用
- 因此, 可以将 L 的第 i 列存放在 A 的第 i 列, 将 U 的第 i 行存放在 A 的第 i 行.

Doolittle 分解法的存储可利用原系数矩阵的存储单元, 存储形式

$$\begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ l_{21} & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \cdots & u_{nn} \end{pmatrix} \rightarrow A$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

例

$$\begin{cases} 2x_1 + 4x_2 + 2x_3 + 6x_4 = 9 \\ 4x_1 + 9x_2 + 6x_3 + 15x_4 = 23 \\ 2x_1 + 6x_2 + 9x_3 + 18x_4 = 22 \\ 6x_1 + 15x_2 + 18x_3 + 40x_4 = 47 \end{cases}$$

解 方程组的系数矩阵和右端项分别为

$$\mathbf{A} = \begin{bmatrix} 2 & 4 & 2 & 6 \\ 4 & 9 & 6 & 15 \\ 2 & 6 & 9 & 18 \\ 6 & 15 & 18 & 40 \end{bmatrix} \quad \mathbf{b} = \begin{bmatrix} 9 \\ 23 \\ 22 \\ 47 \end{bmatrix}$$

§2.3.1 矩阵三角分解法:Doolittle 分解法

1、分解 $A = LU$, 即

$$A = \begin{bmatrix} 1 & & & \\ 2 & 1 & & \\ 1 & 2 & 1 & \\ 3 & 3 & 2 & 1 \end{bmatrix} \begin{bmatrix} 2 & 4 & 2 & 6 \\ & 1 & 2 & 3 \\ & & 3 & 6 \\ & & & 1 \end{bmatrix}$$

2、求解 $Ly = b$, 即

$$\begin{bmatrix} 1 & & & \\ 2 & 1 & & \\ 1 & 2 & 1 & \\ 3 & 3 & 2 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix} = \begin{bmatrix} 9 \\ 23 \\ 22 \\ 47 \end{bmatrix}$$

解得 $y = (9, 5, 3, -1)^T$

§2.3.1 矩阵三角分解法:Doolittle 分解法

求解 $Ux = y$, 即

$$\begin{bmatrix} 2 & 4 & 2 & 6 \\ & 1 & 2 & 3 \\ & & 3 & 6 \\ & & & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 9 \\ 5 \\ 3 \\ -1 \end{bmatrix}$$

解得 $x = (0.5, 2, 3, -1)^T$.

§2.3.2 矩阵三角分解法:Crout 分解法

i) 记 $D = \text{diag}(u_{11}, u_{22}, \dots, u_{nn})$,

$$A = LU = (LD)(D^{-1}U) = \hat{L}\hat{U}, \hat{L} = LD, \hat{U} = D^{-1}U$$

其中 \hat{L} 是下三角阵, \hat{U} 是单位上三角阵. 此分解是惟一的.

$$\begin{aligned} A &= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \\ &= \begin{pmatrix} \hat{l}_{11} & 0 & \cdots & 0 \\ \hat{l}_{21} & \hat{l}_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \hat{l}_{n1} & \hat{l}_{n2} & \cdots & \hat{l}_{nn} \end{pmatrix} \begin{pmatrix} 1 & \hat{u}_{12} & \cdots & \hat{u}_{1n} \\ 0 & 1 & \cdots & \hat{u}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} = \hat{L}\hat{U} \end{aligned}$$

§2.3.2 矩阵三角分解法:Crout 分解法

利用矩阵运算比较两边得其分解公式:

$$\hat{l}_{i1} = a_{i1}, \quad i = 1, 2, \dots, n,$$

$$\hat{u}_{1j} = a_{1j}/\hat{l}_{11}, \quad j = 2, 3, \dots, n,$$

对 $k = 2, 3, \dots, n$,

$$\begin{cases} \hat{l}_{ik} = a_{ik} - \sum_{r=1}^{k-1} \hat{l}_{ir} \hat{u}_{rk}, & i = k, k+1, k+2, \dots, n \\ \hat{u}_{kj} = \left(a_{kj} - \sum_{r=1}^{k-1} \hat{l}_{kr} \hat{u}_{rj} \right) / \hat{l}_{kk}, & j = k+1, k+2, \dots, n \end{cases}$$

求解 $Ax = b$ 等价求解

$$\begin{cases} \hat{L}y = b \\ \hat{U}x = y \end{cases}$$

§2.3.2 矩阵三角分解法:Crout 分解法

ii) 求解方程组 $\hat{L}y = b$, 即

$$\begin{pmatrix} \hat{l}_{11} & 0 & \cdots & 0 \\ \hat{l}_{21} & \hat{l}_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \hat{l}_{n1} & \hat{l}_{n2} & \cdots & \hat{l}_{nn} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

其计算公式为

$$y_1 = b_1 / \hat{l}_{11},$$
$$y_k = \left(b_k - \sum_{r=1}^{k-1} \hat{l}_{kr} y_r \right) / \hat{l}_{kk}, \quad k = 2, 3, \dots, n.$$

§2.3.2 矩阵三角分解法:Crout 分解法

iii) 求解方程组 $\hat{U}x = y$, 即

$$\begin{pmatrix} 1 & \hat{u}_{12} & \cdots & \hat{u}_{1n} \\ 0 & 1 & \cdots & \hat{u}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

其计算公式为

$$x_n = y_n, \\ x_k = y_k - \sum_{r=k+1}^n \hat{u}_{kr}x_r, \quad k = n-1, \cdots, 2, 1.$$

§2.3.2 矩阵三角分解法:Crout 分解法

Crout 分解法的存储可利用原系数矩阵的存储单元, 存储形式

$$\begin{pmatrix} \hat{l}_{11} & \hat{u}_{12} & \cdots & \hat{u}_{1n} \\ \hat{l}_{21} & \hat{l}_{22} & \cdots & \hat{u}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{l}_{n1} & \hat{l}_{n2} & \cdots & \hat{l}_{nn} \end{pmatrix} \rightarrow \mathbf{A}$$

§2.3.2 矩阵三角分解法:Crout 分解法

例用系数矩阵 A 的 Crout 分解求解线性方程组 $Ax = b$. 其中

$$A = \begin{bmatrix} 6 & 2 & 1 & -1 \\ 2 & 4 & 1 & 0 \\ 1 & 1 & 4 & -1 \\ -1 & 0 & -1 & 3 \end{bmatrix}, \quad b = \begin{bmatrix} 6 \\ -1 \\ 5 \\ -5 \end{bmatrix}$$

§2.3.2 矩阵三角分解法:Crout 分解法

分解 $A = \hat{L}\hat{U}$, 即

$$A = \begin{bmatrix} 6 & & & \\ 2 & \frac{10}{3} & & \\ 1 & \frac{2}{3} & \frac{37}{10} & \\ -1 & \frac{1}{3} & -\frac{9}{10} & \frac{191}{74} \end{bmatrix} \begin{bmatrix} 1 & \frac{1}{3} & \frac{1}{6} & -\frac{1}{6} \\ 0 & 1 & \frac{1}{5} & \frac{1}{10} \\ 0 & 0 & 1 & -\frac{9}{37} \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

求解方程组 $\hat{L}y = b$, 得 $y = \left(1, -\frac{9}{10}, \frac{46}{37}, -1\right)^T$

求解方程组 $\hat{U}x = y$, 得 $x = (1, -1, 1, -1)^T$

§2.3.3 矩阵三角分解法: 平方根法 (Cholesky 分解法)

记 $D = \text{diag}(u_{11}, u_{22}, \dots, u_{nn})$, $\hat{U} = D^{-1}U$ $A = LU = (LD)(D^{-1}U) = LD\hat{U}$
(分解惟一)

其中 L 是单位下三角阵, \hat{U} 是单位上三角阵.

如果 A 是对称的, 则 $\hat{U} = L^T$, $A = LDL^T$

如果 A 是对称正定的

$$A = LDL^T = \left(LD^{\frac{1}{2}}\right) \left(LD^{\frac{1}{2}}\right)^T = \bar{L}\bar{L}^T$$

其中 \bar{L} 是下三角阵

§2.3.3 矩阵三角分解法: 平方根法 (Cholesky 分解法)

i)

$$\begin{aligned} \mathbf{A} &= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \\ &= \begin{pmatrix} \tilde{l}_{11} & 0 & \cdots & 0 \\ \tilde{l}_{21} & \tilde{l}_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{l}_{n1} & \tilde{l}_{n2} & \cdots & \tilde{l}_{nn} \end{pmatrix} \begin{pmatrix} \tilde{l}_{11} & \tilde{l}_{21} & \cdots & \tilde{l}_{n1} \\ 0 & \tilde{l}_{22} & \cdots & \tilde{l}_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \tilde{l}_{nn} \end{pmatrix} = \tilde{L}\tilde{L}^T \end{aligned}$$

称为矩阵的 Cholesky 分解.

利用矩阵运算比较两边得其分解公式:

$$\begin{cases} \tilde{l}_{11} = (a_{11})^{1/2}, \\ \tilde{l}_{i1} = a_{i1}/\tilde{l}_{11}, \quad i = 2, 3, \dots, n. \end{cases}$$

§2.3.3 矩阵三角分解法: 平方根法 (Cholesky 分解法)

对 $k = 2, 3, \dots, n$,

$$\begin{cases} \tilde{l}_{kk} = \left(a_{kk} - \sum_{r=1}^{k-1} \tilde{l}_{kr}^2 \right)^{1/2}, \\ \tilde{l}_{ik} = \left(a_{ik} - \sum_{r=1}^{k-1} \tilde{l}_{ir} \tilde{l}_{kr} \right) / \tilde{l}_{kk}, \quad i = k+1, k+2, \dots, n. \end{cases}$$

ii) 求解方程组 $\tilde{L}y = b$, 即

$$\begin{pmatrix} \tilde{l}_{11} & 0 & \cdots & 0 \\ \tilde{l}_{21} & \tilde{l}_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{l}_{n1} & \tilde{l}_{n2} & \cdots & \tilde{l}_{nn} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

其计算公式为

$$\begin{aligned} y_1 &= b_1 / \tilde{l}_{11} \\ y_k &= \left(b_k - \sum_{r=1}^{k-1} \tilde{l}_{kr} y_r \right) / \tilde{l}_{kk}, \quad k = 2, 3, \dots, n. \end{aligned}$$

§2.3.3 矩阵三角分解法: 平方根法 (Cholesky 分解法)

iii) 求解方程组 $\tilde{L}^T x = y$, 即

$$\begin{pmatrix} \tilde{l}_{11} & \tilde{l}_{21} & \cdots & \tilde{l}_{n1} \\ 0 & \tilde{l}_{22} & \cdots & \tilde{l}_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \tilde{l}_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

其计算公式为

$$x_n = y_n / \tilde{l}_{nn},$$
$$x_k = \left(y_k - \sum_{j=k}^n \tilde{l}_{jr} x_r \right) / \tilde{l}_{kk}, \quad k = n-1, \dots, 2, 1.$$

§2.3.3 矩阵三角分解法: 平方根法 (Cholesky 分解法)

Cholesky 分解法的存储可利用原系数矩阵 (对称) 的存储单元, 它没有增加储存单元, 存储形式.

$$\begin{pmatrix} \tilde{l}_{11} & & \cdots & \\ \tilde{l}_{21} & \tilde{l}_{22} & \cdots & \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{l}_{n1} & \tilde{l}_{n2} & \cdots & \tilde{l}_{nn} \end{pmatrix} \rightarrow \mathbf{A}$$

平方根法是用于解系数矩阵为正定矩阵的线性方程组.

§2.3.3 矩阵三角分解法: 平方根法 (Cholesky 分解法)

例 用平方根法 (Cholesky 分解) 解方程组

$$\begin{bmatrix} 3 & 2 & 3 \\ 2 & 2 & 0 \\ 3 & 0 & 12 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \\ 7 \end{bmatrix}$$

解 由于系数矩阵 A 对称正定, 故一定有分解形式 $A = \tilde{L}\tilde{L}^T$ 其中 \tilde{L} 为下三角阵.
对系数矩阵进行 Cholesky 分解 $A = \tilde{L}\tilde{L}^T$, 即

$$\begin{bmatrix} 3 & 2 & 3 \\ 2 & 2 & 0 \\ 3 & 0 & 12 \end{bmatrix} = \begin{bmatrix} \tilde{l}_{11} & & \\ \tilde{l}_{21} & \tilde{l}_{22} & \\ \tilde{l}_{31} & \tilde{l}_{32} & \tilde{l}_{33} \end{bmatrix} \begin{bmatrix} \tilde{l}_{11} & \tilde{l}_{21} & \tilde{l}_{31} \\ & \tilde{l}_{22} & \tilde{l}_{32} \\ & & \tilde{l}_{33} \end{bmatrix}$$

§2.3.3 矩阵三角分解法: 平方根法 (Cholesky 分解法)

由公式得 $\tilde{l}_{11} = \sqrt{3}$, $\tilde{l}_{21} = \frac{2}{\sqrt{3}}$, $\tilde{l}_{31} = \sqrt{3}$ $\tilde{l}_{22} = \sqrt{\frac{2}{3}}$, $\tilde{l}_{32} = -\sqrt{6}$, $\tilde{l}_{33} = \sqrt{3}$

解方程组 $\tilde{L}y = b$, 即
$$\begin{bmatrix} \sqrt{3} \\ \frac{2}{\sqrt{3}} & \sqrt{\frac{2}{3}} \\ \sqrt{3} & -\sqrt{6} & \sqrt{3} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \\ 7 \end{bmatrix}$$

得 $y = \left(\frac{5}{\sqrt{3}}, -\frac{1}{\sqrt{6}}, \frac{1}{\sqrt{3}}\right)^T$

解方程组 $\tilde{L}^T x = y$, 即
$$\begin{bmatrix} \sqrt{3} & \frac{2}{\sqrt{3}} & \sqrt{3} \\ & \sqrt{\frac{2}{3}} & -\sqrt{6} \\ & & \sqrt{3} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} \frac{5}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{3}} \end{bmatrix} \text{ 得 } x = \left(1, \frac{1}{2}, \frac{1}{3}\right)^T$$

§2.3.3 矩阵三角分解法: 改进的 Cholesky 分解法

Cholesky 分解的缺点是需要作开方运算. 改为使用分解

i) 设 A 对称

$$\begin{aligned} A &= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 & \cdots & 0 \\ l_{21} & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \cdots & 1 \end{pmatrix} \begin{pmatrix} d_1 & & & \\ & d_2 & & \\ & & \ddots & \\ & & & d_n \end{pmatrix} \begin{pmatrix} 1 & l_{21} & \cdots & l_{n1} \\ 0 & 1 & \cdots & l_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} \\ &= \mathbf{L} \mathbf{D} \mathbf{L}^T \end{aligned}$$

§2.3.3 矩阵三角分解法: 改进的 Cholesky 分解法

利用矩阵运算比较两边得其分解公式:

$$\begin{cases} d_1 = a_{11}, \\ l_{i1} = a_{i1}/d_1, \quad i = 2, 3, \dots, n. \end{cases}$$

对 $k = 2, 3, \dots, n$,

$$\begin{cases} d_k = a_{kk} - \sum_{r=1}^{k-1} l_{kr}^2 d_r, \\ l_{ik} = \left(a_{ik} - \sum_{r=1}^{k-1} l_{ir} d_r l_{kr} \right) / d_k, \quad i = k+1, k+2, \dots, n. \end{cases}$$

分解唯一

§2.3.3 矩阵三角分解法: 改进的 Cholesky 分解法

ii) 求解方程组 $Ly = b$

$$y_1 = b_1,$$

$$y_k = b_k - \sum_{r=1}^{k-1} l_{kr} y_r, \quad k = 2, 3, \dots, n.$$

iii) 求解方程组 $L^T x = D^{-1} y$

$$x_n = y_n / d_n,$$

$$x_k = y_k / d_k - \sum_{r=k+1}^n l_{rk} x_r, \quad k = n-1, \dots, 2, 1.$$

§2.3.3 矩阵三角分解法: 改进的 Cholesky 分解法

改进的 Cholesky 分解法的存储可利用原系数矩阵 (对称) 的存储单元, 它没有增加储存单元, 存储形式.

$$\begin{pmatrix} d_1 & & \cdots & \\ l_{21} & d_2 & \cdots & \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \cdots & d_n \end{pmatrix} \rightarrow \mathbf{A}$$

§2.3.3 矩阵三角分解法: 改进的 Cholesky 分解法

例 用改进的平方根法解方程组

$$\begin{bmatrix} 3 & 3 & 5 \\ 3 & 5 & 9 \\ 5 & 9 & 17 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 10 \\ 16 \\ 30 \end{bmatrix}$$

解 系数矩阵是对称的, 故可分解为 LDL^T , 设有分解

$$\begin{bmatrix} 3 & 3 & 5 \\ 3 & 5 & 9 \\ 5 & 9 & 17 \end{bmatrix} = \begin{bmatrix} 1 & & \\ l_{21} & 1 & \\ l_{31} & l_{32} & 1 \end{bmatrix} \begin{bmatrix} d_1 & & \\ & d_2 & \\ & & d_3 \end{bmatrix} \begin{bmatrix} 1 & l_{21} & l_{31} \\ & 1 & l_{32} \\ & & 1 \end{bmatrix}$$

由公式得

$$\begin{aligned} d_1 &= 3, & l_{21} &= 1, & l_{31} &= \frac{5}{3} \\ d_2 &= 2, & l_{32} &= 2, & d_3 &= \frac{2}{3} \end{aligned}$$

§2.3.3 矩阵三角分解法: 改进的 Cholesky 分解法

解方程组 $Ly = b$, 即

$$\begin{bmatrix} 1 & & \\ 1 & 1 & \\ \frac{5}{3} & 2 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} 10 \\ 16 \\ 30 \end{bmatrix}$$

得 $y = (10, 6, \frac{4}{3})^T$

解方程组 $L^T x = D^{-1}y$, 即

$$\begin{bmatrix} 1 & 1 & \frac{5}{3} \\ & 1 & 2 \\ & & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} \frac{1}{3} & & \\ & \frac{1}{2} & \\ & & \frac{3}{2} \end{bmatrix} \begin{bmatrix} 10 \\ 6 \\ \frac{4}{3} \end{bmatrix}$$

得 $x = (1, -1, 2)^T$

§2.3.4 解三对角方程组的追赶法

设方程组 $Ax = d$

它的系数方阵 A 是一个三对角方阵

$$A = \begin{pmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & c_3 & \\ & & \ddots & \ddots & \ddots \\ & & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & & a_n & b_n \end{pmatrix}$$

其中 $|i - j| > 1$ 时 $a_{ij} = 0$, 且满足如下的对角占优条件

- (i) $|b_1| > |c_1| > 0$,
- (ii) $|b_n| > |a_n| > 0$
- (iii) $|b_i| \geq |a_i| + |c_i|, a_i, c_i \neq 0, \quad i = 2, 3, \dots, n - 1.$

§2.3.4 解三对角方程组的追赶法

i) 对 A 进行分解

$$\begin{pmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & c_3 & \\ & & \ddots & \ddots & \ddots \\ & & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & & a_n & b_n \end{pmatrix} = \begin{pmatrix} \alpha_1 & & & & \\ \gamma_2 & \alpha_2 & & & \\ & \ddots & \ddots & & \\ & & \gamma_{n-1} & \alpha_{n-1} & \\ & & & \gamma_n & \alpha_n \end{pmatrix} \begin{pmatrix} 1 & \beta_1 & & & \\ & 1 & \beta_2 & & \\ & & \ddots & \ddots & \\ & & & 1 & \beta_{n-1} \\ & & & & 1 \end{pmatrix}$$

§2.3.4 解三对角方程组的追赶法

利用矩阵运算比较两边推得其分解公式：

$$\left\{ \begin{array}{l} \alpha_1 = b_1, \beta_1 = c_1/b_1, \\ \gamma_i = a_i, \quad i = 2, \dots, n, \\ \alpha_i = b_i - a_i\beta_{i-1}, \quad i = 2, \dots, n, \\ \beta_i = c_i/(b_i - a_i\beta_{i-1}), \quad i = 2, \dots, n-1, \end{array} \right.$$

α_i , 可由 a_i, b_i, β_{i-1} , 产生, 真正需计算的是 β_i . β_i 的递推公式为

$$\left\{ \begin{array}{l} \beta_1 = c_1/b_1, \\ \beta_i = c_i/(b_i - a_i\beta_{i-1}), \quad i = 2, \dots, n-1 \end{array} \right.$$

$$\left\{ \begin{array}{l} \alpha_1 = b_1, \\ \gamma_i = a_i, \quad i = 2, \dots, n, \\ \alpha_i = b_i - a_i\beta_{i-1}, \quad i = 2, \dots, n, \end{array} \right.$$

§2.3.4 解三对角方程组的追赶法

ii) 求解方程组 $\hat{L}y = d$, 即

$$\begin{pmatrix} \alpha_1 & & & & \\ \gamma_2 & \alpha_2 & & & \\ & \ddots & \ddots & & \\ & & \gamma_{n-1} & \alpha_{n-1} & \\ & & & \gamma_n & \alpha_n \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{pmatrix}$$

其计算公式为

$$\begin{cases} y_1 = d_1/b_1 \\ y_k = (d_k - a_k y_{k-1}) / (b_k - a_k \beta_{k-1}), \quad (k = 2, 3, \dots, n) \end{cases}$$

§2.3.4 解三对角方程组的追赶法

iii) 求解方程组 $\hat{U}x = y$, 即

$$\begin{pmatrix} 1 & \beta_1 & & & \\ & 1 & \beta_2 & & \\ & & \ddots & \ddots & \\ & & & 1 & \beta_{n-1} \\ & & & & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

其计算公式为

$$\begin{cases} x_n = y_n, \\ x_k = y_k - \beta_k x_{k+1}, \quad k = n-1, n-2, \dots, 2, 1. \end{cases}$$

§2.3.4 解三对角方程组的追赶法

将求系数

$$\beta_1 \rightarrow \beta_2 \rightarrow \cdots \rightarrow \beta_{n-1}$$

及

$$y_1 \rightarrow y_2 \rightarrow \cdots \rightarrow y_n$$

的过程称之为追的过程;
求

$$x_n \rightarrow x_{n-1} \rightarrow \cdots \rightarrow x_2 \rightarrow x_1$$

的过程称之为赶的过程。

§2.4.1 向量范数

设 \mathbb{R}^n 为实 n 维向量空间。

定义 若向量 $x \in \mathbb{R}^n$ 的某个实值函数 $N(x) = \|x\|$ 满足如下条件

- (I) 非负性: $\|x\| \geq 0$ 且 $\|x\| = 0 \Leftrightarrow x = 0$
- (II) 齐次性: $\|\lambda x\| = |\lambda| \cdot \|x\|$, $\forall \lambda \in \mathbb{R}$
- (III) 三角不等式

$$\|x + y\| \leq \|x\| + \|y\|, \quad \forall x, y \in \mathbb{R}^n.$$

则称 $\|\cdot\|$ 为 \mathbb{R}^n 上的一种向量范数.

§2.4.1 向量范数: 常用的向量范数

在 \mathbb{R}^n 上的向量 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$ $\mathbf{y} = (y_1, y_2, \dots, y_n)^T \in \mathbb{R}^n$

$$(\mathbf{x}, \mathbf{y}) := \mathbf{x}^T \mathbf{y} = \sum_{i=1}^n x_i y_i, \quad (\mathbf{x}, \mathbf{y}) = (\mathbf{y}, \mathbf{x}).$$

常用向量范数: 在 \mathbb{R}^n 上的向量 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$

1. $\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$, 称为 ∞ -范数

2. $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$, 称为 1-范数

3. $\|\mathbf{x}\|_2 = (\mathbf{x}, \mathbf{x})^{1/2} = \left(\sum_{i=1}^n |x_i|^2 \right)^{1/2}$, 称为 2-范数

4. $\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$, $1 \leq p < \infty$, 称为 p -范数

§2.4.1 向量范数: 有关定理

定理 1 (范数连续性定理) 设 $N(\boldsymbol{x}) = \|\boldsymbol{x}\|$ 为 \mathbb{R}^n 上任一向量范数, 则 $N(\boldsymbol{x})$ 是 \boldsymbol{x} 的连续函数.

定理 2 (范数等价性定理) 设 $\|\boldsymbol{x}\|_s, \|\boldsymbol{x}\|_t$ 为 \mathbb{R}^n 上任意两种向量范数, 则存在常数 $c_1, c_2 > 0$, 使得

$$c_1 \|\boldsymbol{x}\|_s \leq \|\boldsymbol{x}\|_t \leq c_2 \|\boldsymbol{x}\|_s, \quad \forall \boldsymbol{x} \in \mathbb{R}^n.$$

如果

$$\lim_{k \rightarrow \infty} x_i^{(k)} = x_i, \quad i = 1, \dots, n.$$

写为

$$\lim_{k \rightarrow \infty} \boldsymbol{x}^{(k)} = \boldsymbol{x}.$$

定理 3 $\|\cdot\|$ 为有限维空间 \mathbb{R}^n 上的范数,

$$\lim_{k \rightarrow \infty} \boldsymbol{x}^{(k)} = \boldsymbol{x} \Leftrightarrow \lim_{k \rightarrow \infty} \|\boldsymbol{x} - \boldsymbol{x}^{(k)}\| = 0,$$

其中 $\boldsymbol{x} \in \mathbb{R}^n$, 向量序列 $\{\boldsymbol{x}^{(k)}\}$ 的元素属于 \mathbb{R}^n .

§2.4.2 矩阵范数

定义 若矩阵 $A \in \mathbb{R}^{n \times n}$ 的某个实值函数 $N(A) = \|A\|$ 满足如下条件:

- (I) 非负性: $\|A\| \geq 0$ 且 $\|A\| = 0 \Leftrightarrow A = 0$
- (II) 齐次性: $\|\lambda A\| = |\lambda| \cdot \|A\|, \forall \lambda \in \mathbb{R}$
- (III) 三角不等式: $\|A + B\| \leq \|A\| + \|B\|, \forall A, B \in \mathbb{R}^{n \times n}$
- (IV) $\|AB\| \leq \|A\| \cdot \|B\|, \forall A, B \in \mathbb{R}^{n \times n}$

则称 $\|\cdot\|$ 为 $\mathbb{R}^{n \times n}$ 上的一种矩阵范数.

例对于实矩阵 $A = (a_{ij})_{n \times n}$

$$\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}}$$

是一种矩阵范数, 称为矩阵的 Frobenius 范数, 简称矩阵的 F 范数.

§2.4.2 矩阵范数

考虑到矩阵范数总是与向量范数联系在一起的. 对于给定向量范数 $\|\cdot\|$ 和矩阵范数, 如果对任一个 n 维向量 x 和任一 n 阶方阵 A , 都有不等式 $\|Ax\| \leq \|A\| \cdot \|x\|$ 成立, 则称所给的矩阵范数与向量范数是相容的.

下面给出一种定义矩阵范数的方法, 它是由向量范数诱导出来的相容范数.

定义 设 n 维向量 x 和 n 阶方阵 A , 且给定一种向量范数 $\|x\|_v$, 则称

$$\|A\|_v = \sup_{x \neq 0} \frac{\|Ax\|_v}{\|x\|_v}$$

或

$$\|A\|_v = \sup_{\|x\|_v=1} \|Ax\|_v$$

为矩阵 A 的由向量范数 $\|x\|_v$ 产生的**从属范数**或**算子范数**. 单位矩阵的任一种从属范数都为 1.

矩阵的从属范数 $\|A\|_v$ 依赖于向量范数 $\|x\|_v$ 的具体含义.

§2.4.2 矩阵范数

定义 设 n 阶方阵 A 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则称

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$$

为 A 的谱半径 ($|\lambda_i|$ 为 λ_i 的模) .

方阵 A 的由向量 1-范数, 2-范数, ∞ -范数产生的算子范数分别为

定理 设 n 阶方阵 $A = (a_{ij})_{n \times n}$, 则

1. $\|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$, 称为 ∞ -范数 (行范数)

2. $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$, 称为 1-范数 (列范数)

3. $\|A\|_2 = \sqrt{\rho(A^T A)}$, 称为 2-范数

§2.4.2 矩阵范数

证明 $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$

证明 设 $x = (x_1, x_2, \dots, x_n)^T \neq 0$, 不妨设 $A \neq 0$. 记

$$t = \|x\|_\infty = \max_{1 \leq i \leq n} |x_i|, \quad \mu = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

则

$$\|Ax\|_\infty = \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_i \sum_{j=1}^n |a_{ij}| |x_j| \leq t \max_i \sum_{j=1}^n |a_{ij}|$$

这说明对任何非零 $x \in \mathbb{R}^n$, 有

$$\frac{\|Ax\|_\infty}{\|x\|_\infty} \leq \mu \Rightarrow \|A\|_\infty \leq \mu$$

§2.4.2 矩阵范数

下面来说明有一向量 $x_0 \neq 0$, 使 $\frac{\|Ax_0\|_\infty}{\|x_0\|_\infty} = \mu$.

设

$$\mu = \sum_{j=1}^n |a_{i_0 j}|,$$

取向量

$$x_0 = (x_1, x_2, \dots, x_n)^T,$$

其中

$$x_j = \operatorname{sgn}(a_{i_0 j}) \quad (j = 1, 2, \dots, n).$$

显然

$$\|x_0\|_\infty = 1,$$

§2.4.2 矩阵范数

且 Ax_0 的第 i_0 个分量为

$$\sum_{j=1}^n a_{i_0 j} x_j = \sum_{j=1}^n |a_{i_0 j}|,$$

这 i 说明

$$\|Ax_0\|_\infty = \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} x_j \right| = \sum_{j=1}^n |a_{i_0 j}| = \mu$$

这里用到

$$\left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{j=1}^n |a_{ij}| \leq \sum_{j=1}^n |a_{i_0 j}| = \sum_{j=1}^n |a_{i_0 j}| x_j.$$

§2.4.2 矩阵范数

证明 $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$

证明:

$$\begin{aligned}\|Ax\|_1 &= \sum_{i=1}^n \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}| |x_j| \\&= \sum_{j=1}^n \left(\sum_{i=1}^n |a_{ij}| \right) |x_j| \leq \sum_{j=1}^n \left(\max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \right) |x_j| \\&= \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \cdot \sum_{j=1}^n |x_j| = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \cdot \|x\|_1\end{aligned}$$

于是

$$\frac{\|Ax\|_1}{\|x\|_1} \leq \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

§2.4.2 矩阵范数

下面只需证明有一向量 $x_0 \neq 0$, 使得

$$\frac{\|Ax_0\|_1}{\|x_0\|_1} = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|.$$

设

$$\sum_{i=1}^n |a_{ij_0}| = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

取 $x_0 = (0, 0, \dots, 0, x_{j_0}, 0, \dots, 0)^T$, 其中, $x_{j_0} = 1$, 则

$$\begin{aligned}\|Ax_0\|_1 &= \sum_{i=1}^n \left| \sum_{j=1}^n a_{ij} x_j \right| = \sum_{i=1}^n |a_{ij_0} x_{j_0}| \\ &= \sum_{i=1}^n |a_{ij_0}| = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|\end{aligned}$$

§2.4.2 矩阵范数

而

$$\|x_0\|_1 = |x_{j_0}| = 1,$$

所以

$$\max_{\|x\| \neq 0} \frac{\|Ax\|_1}{\|x\|_1} = \frac{\|Ax_0\|_1}{\|x_0\|_1} = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

即

$$\|A\|_1 = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|.$$

§2.4.2 矩阵范数

证明

$$\|A\|_2 = \sqrt{\rho(A^T A)}$$

证明: 由于 $A^T A$ 为实对称半正定矩阵, 存在正交矩阵 U , 满足

$$U^T A^T A U = \text{diag}(\mu_1, \dots, \mu_n)$$

其中 μ_i 为 $A^T A$ 的特征值. 令 $y = U^T x$, 则

$$\begin{aligned}\|A\|_2 &= \sup_{x \neq 0} \sqrt{\frac{(A^T A x, x)}{(x, x)}} = \sup_{y \neq 0} \sqrt{\frac{(U^T A^T A U y, y)}{(y, y)}} \\ &= \sup_{y \neq 0} \sqrt{\frac{\sum_{i=1}^n \mu_i |y_i|^2}{\sum_{i=1}^n |y_i|^2}} = \sqrt{\max_{i=1, \dots, n} |\mu_i|}\end{aligned}$$

§2.4.2 矩阵范数

定理 (Jordan 标准形) 设 $n \times n$ 的方阵 A , 则 A 可通过相似变换化为 Jordan 标准形矩阵 J , 它是含有 s 个对角块的块对角矩阵. 即存在可逆矩阵 P , 使

$$J = P^{-1}AP = \begin{bmatrix} J_{n_1}(\lambda_1) & & & \\ & J_{n_2}(\lambda_2) & & \\ & & \ddots & \\ & & & J_{n_s}(\lambda_s) \end{bmatrix}$$

其中每个对角块 $J_m(\lambda)$

$$J_m(\lambda) = \begin{bmatrix} \lambda & 1 & & & \\ & \lambda & 1 & & \\ & & \ddots & \ddots & \\ & & & \lambda & 1 \\ & & & & \lambda \end{bmatrix}_{m \times m}$$

§2.4.2 矩阵范数

$$n_1 + n_2 + \cdots + n_s = n$$

$\lambda_1, \lambda_2, \dots, \lambda_s$ 为 A 的特征值, 不要求它们都不相同,

$$\mathbf{J}_1(\lambda) = [\lambda], \mathbf{J}_2(\lambda) = \begin{bmatrix} \lambda & 1 \\ 0 & \lambda \end{bmatrix}$$

§2.4.2 矩阵范数

定理 A 为方阵, 对于任意算子范数 $\|\cdot\|$,

$$\rho(A) \leq \|A\|.$$

定理 A 为方阵, 对任意实数 $\varepsilon > 0$. 至少存在一种算子范数 $\|\cdot\|_\varepsilon$, 满足

$$\|A\|_\varepsilon \leq \rho(A) + \varepsilon.$$

$$\rho(A) = \inf_{\|\cdot\|} \|A\|.$$

若 A 实对称矩阵, 则 $\rho(A) = \|A\|_2$

定理 A 为方阵, 对于任意算子范数 $\|\cdot\|$, 则

$$\lim_{m \rightarrow \infty} \|A^m\|^{1/m} = \rho(A).$$

§2.4.2 矩阵范数

定理 已知 $\|x\|_\alpha$ 为 \mathbb{R}^n 上一种向量范数, 从属于它的矩阵范数为 $\|A\|_\alpha$. 设 $P \in \mathbb{R}^{n \times n}$, $\det P \neq 0$, 则

(1) \mathbb{R}^n 到 \mathbb{R} 的映射 $x \mapsto \|Px\|_\alpha$ 定义了 \mathbb{R}^n 上另一种向量范数, 它与 P 有关, 记为

$$\|x\|_{P,\alpha} = \|Px\|_\alpha$$

(2) 从属于向量范数 $\|x\|_{P,\alpha}$ 的矩阵范数为

$$\|A\|_{P,\alpha} = \|PAP^{-1}\|_\alpha$$

§2.4.2 矩阵范数

由关于 Jordan 标准形的定理, 对任意的 $A \in \mathbb{R}^{n \times n}$, 总存在非奇异的方阵 P , 使 $J = P^{-1}AP = \text{diag}[J_1, J_2, \dots, J_s]$, 其中 Jordan 子阵 $J_i (i = 1, 2, \dots, s)$ 又有块对角的形式. 总的来说可以写成

$$J = P^{-1}AP = \begin{bmatrix} \lambda_1 & \delta_1 & & & \\ & \lambda_2 & \delta_2 & & \\ & & \ddots & \ddots & \\ & & & \lambda_{n-1} & \delta_{n-1} \\ & & & & \lambda_n \end{bmatrix}$$

其中 n 个特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ 可以有相重的, 而 $\delta_i (i = 1, 2, \dots, n-1)$ 等于 0 或 1. 对于 $\varepsilon > 0$, 定义对角矩阵

$$D_\varepsilon = \text{diag}(1, \varepsilon, \varepsilon^2, \dots, \varepsilon^{n-1})$$

§2.4.2 矩阵范数

易证 $D_\varepsilon^{-1}JD_\varepsilon$ 与 J 有相同的分块形式, 可写成

$$J_\varepsilon = D_\varepsilon^{-1}JD_\varepsilon = \begin{bmatrix} \lambda_1 & \varepsilon\delta_1 & & & \\ & \lambda_2 & \varepsilon\delta_2 & & \\ & & \ddots & \ddots & \\ & & & \lambda_{n-1} & \varepsilon\delta_{n-1} \\ & & & & \lambda_n \end{bmatrix}$$

由 (4. 14) 式,

$$\|J_\varepsilon\|_\infty = \|D_\varepsilon^{-1}P^{-1}APD_\varepsilon\|_\infty = \max_{1 \leq i \leq n} (|\lambda_i| + \varepsilon\delta_i) \leq \rho(A) + \varepsilon$$

其中设 $\delta_n = 0$. 而 $D_\varepsilon^{-1}P^{-1}$ 非奇异, $\|J_\varepsilon\|_\infty$ 是矩阵 A 从属于向量范数 $\|D_\varepsilon^{-1}P^{-1}x\|_\infty$ 的矩阵范数, 结论

$$\|A\|_\varepsilon \leq \rho(A) + \varepsilon$$

成立.

§2.4.2 矩阵范数

设矩阵序列 $\{A^{(k)}\} \in \mathbb{R}^{n \times n}$, 矩阵 $A \in \mathbb{R}^{n \times n}$, 如果

$$\lim_{k \rightarrow \infty} \|A^{(k)} - A\| = 0,$$

称 $\{A^{(k)}\}$ 收敛到 A .

定理 设 A 为方阵, 则

$$\lim_{k \rightarrow \infty} A^k = \mathbf{0} \Leftrightarrow \rho(A) < 1.$$

更多的, 几何序列 $\sum_{k=0}^{\infty} A^k$ 收敛的充分必要条件为

$$\rho(A) < 1.$$

收敛时

$$\sum_{k=0}^{\infty} A^k = (I - A)^{-1}$$

§2.4.2 矩阵范数

$$\lim_{k \rightarrow \infty} \mathbf{A}^k = \mathbf{0} \Leftrightarrow \rho(\mathbf{A}) < 1.$$

存在一种矩阵的算子范数

$$\|\mathbf{A}\| \leq \rho(\mathbf{A}) + (1 - \rho(\mathbf{A}))/2 < 1, \quad \|\mathbf{A}^k\| \leq \|\mathbf{A}\|^k$$

$$\lim_{k \rightarrow \infty} \|\mathbf{A}^k\| = 0 \Rightarrow \lim_{k \rightarrow \infty} \mathbf{A}^k = \mathbf{0}$$

$$\lim_{k \rightarrow \infty} \mathbf{A}^k = \mathbf{0} \Rightarrow \rho(\mathbf{A}) < 1.$$

设 λ 为 \mathbf{A} 的特征值, \mathbf{x} 为相应的特征向量

$$\mathbf{A}^k \mathbf{x} = \lambda^k \mathbf{x}$$

$$\lim_{k \rightarrow \infty} \mathbf{A}^k \mathbf{x} = \mathbf{0} = \lim_{k \rightarrow \infty} \lambda^k \mathbf{x} \Rightarrow \lim_{k \rightarrow \infty} \lambda^k = 0 \Rightarrow |\lambda| < 1$$

所以 $\rho(\mathbf{A}) < 1$.

§2.4.2 矩阵范数

定理 如果 A 为方阵, 算子范数 $\|A\| < 1$, 则 $I \pm A$ 为非奇异矩阵, 且

$$\frac{1}{1 + \|A\|} \leq \|(I \pm A)^{-1}\| \leq \frac{1}{1 - \|A\|}$$

证: 令 $B = (I \pm A)^{-1}$, 则

$$\|(I \pm A)B\| = \|I\| = 1$$

由于

$$1 = \|(I \pm A)B\| \leq \|B\| \|(I \pm A)\| \leq \|B\| (1 + \|A\|)$$

得

$$\frac{1}{1 + \|A\|} \leq \|B\| = \|(I \pm A)^{-1}\|$$

§2.4.2 矩阵范数

由于

$$1 = \|(I \pm A)B\| = \|B \pm BA\|$$

$$\begin{aligned}\|B \pm BA\| + \|B\|\|A\| &\geq \|B \pm BA\| + \|BA\| \geq \|B \pm BA \mp BA\| \\ &= \|B\|\end{aligned}$$

所以

$$1 = \|B \pm BA\| \geq \|B\| - \|B\|\|A\|$$

得

$$\|(I \pm A)^{-1}\| = \|B\| \leq \frac{1}{1 - \|A\|}$$

§2.5.1 矩阵的条件数

定义 设 A 为非奇异矩阵, 称数 $\text{cond}(A) = \|A\| \cdot \|A^{-1}\|$ 为矩阵 A 的条件数.

$$\text{cond}(A) = \|A\| \cdot \|A^{-1}\| \geq \|AA^{-1}\| = 1$$

条件数与所取范数有关, 因此有时详细记为

$$\text{cond}(A)_v = \|A\|_v \cdot \|A^{-1}\|_v$$

通常使用的条件数有

1.

$$\text{cond}(A)_\infty = \|A^{-1}\|_\infty \|A\|_\infty$$

2. A 的谱条件数

$$\text{cond}(A)_2 = \|A\|_2 \|A^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A A^T)}}$$

§2.5.1 矩阵的条件数

当 A 为实对称矩阵时

$$\text{cond}(A)_2 = \frac{|\lambda_1|}{|\lambda_n|}$$

其中 λ_1, λ_n 为 A 的绝对值最大和绝对值最小的特征值.

§2.5.1 矩阵的条件数

例 计算 3 阶 Hilbert 矩阵

$$\mathbf{H}_3 = \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \end{pmatrix}$$

的条件数 $\text{cond}(\mathbf{H}_3)_\infty$

解

$$\mathbf{H}_3^{-1} = \begin{pmatrix} 9 & -36 & 30 \\ -36 & 192 & -180 \\ 30 & -180 & 180 \end{pmatrix}$$

$$\|\mathbf{H}_3\|_\infty = 11/6, \|\mathbf{H}_3^{-1}\|_\infty = 408$$

$$\text{cond}(\mathbf{H}_3)_\infty = \|\mathbf{H}_3\|_\infty \|\mathbf{H}_3^{-1}\|_\infty = 748$$

§2.5.2 误差分析

方程组

$$\begin{pmatrix} 1 & 1 \\ 1 & 1.0001 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$$

记为 $Ax = b$, 其精确解为 $x = (2, 0)^T$ 当常数项有微小变化时, 即考虑方程组

$$\begin{pmatrix} 1 & 1 \\ 1 & 1.0001 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 2.0001 \end{pmatrix}$$

记为 $A(x + \delta x) = b + \delta b$, $\delta b = (0, 0.0001)^T$

其精确解为 $x + \delta x = (1, 1)^T$

§2.5.2 误差分析

考虑的问题:

$$Ax = b \quad (5)$$

$$(A + \delta A)(x + \delta x) = b + \delta b \quad (6)$$

(6)是(5)的近似方程组, 研究二者解的近似程度. 研究两个方程的精确解 x 与 $x + \delta x$ 的差 δx 与扰动 δA 和 δb 的关系。

§2.5.2 误差分析: A 为精确, b 有小扰动 δb

设 δb 为 b 的扰动, 引起解 x 的扰动为 δx ,

$$A(x + \delta x) = b + \delta b$$

则

$$\delta x = A^{-1} \delta b$$

$$\|\delta x\| \leq \|A^{-1}\| \|\delta b\|$$

$$\|x\| \geq \frac{\|Ax\|}{\|A\|} = \frac{\|b\|}{\|A\|}$$

所以

$$\frac{\|\delta x\|}{\|x\|} \leq \|A\| \|A^{-1}\| \frac{\|\delta b\|}{\|b\|} = \text{cond}(A) \frac{\|\delta b\|}{\|b\|}$$

§2.5.2 误差分析: A 为精确, b 有小扰动 δb

设 δb 为 b 的扰动, 引起解 x 的扰动为 δx ,

$$A(x + \delta x) = b + \delta b$$

则

$$A\delta x = \delta b$$

$$\|x\| = \|A^{-1}b\| \leq \|A^{-1}\| \|b\|$$

$$\|\delta x\| \geq \frac{\|A\delta x\|}{\|A\|} = \frac{\|\delta b\|}{\|A\|}$$

所以

$$\frac{\|\delta x\|}{\|x\|} \geq \frac{1}{\|A\| \|A^{-1}\|} \frac{\|\delta b\|}{\|b\|} = \frac{1}{\text{cond}(A)} \frac{\|\delta b\|}{\|b\|}$$

§2.5.2 误差分析: A 有小扰动 δA , b 为精确

方程组 $Ax = b$ 的系数阵 A 的扰动对解的影响

设 δA 为 A 的扰动, 引起解 x 的扰动为 δx , 则

$$(A + \delta A)(x + \delta x) = b$$

$$A\delta x + \delta A(x + \delta x) = 0$$

$$\delta x = -A^{-1}\delta A(x + \delta x)$$

$$\|\delta x\| \leq \|A^{-1}\| \|\delta A\| (\|x\| + \|\delta x\|)$$

假设 δA 足够小, 使 $\|A^{-1}\| \|\delta A\| < 1$

$$\begin{aligned} \frac{\|\delta x\|}{\|x\|} &\leq \frac{\|A^{-1}\| \|\delta A\|}{1 - \|A^{-1}\| \|\delta A\|} = \frac{\|A\| \|A^{-1}\| \frac{\|\delta A\|}{\|A\|}}{1 - \|A\| \|A^{-1}\| \frac{\|\delta A\|}{\|A\|}} \\ &= \frac{\text{cond}(A) \frac{\|\delta A\|}{\|A\|}}{1 - \text{cond}(A) \frac{\|\delta A\|}{\|A\|}} \end{aligned}$$

§2.5.2 误差分析: A 有小扰动 δA , b 有小扰动 δb

方程组 $Ax = b$ 的系数阵 A 的扰动对解的影响

设 δA 为 A 的扰动, 引起解 x 的扰动为 δx , 则

$$(A + \delta A)(x + \delta x) = b + \delta b$$

$$A\delta x + \delta A(x + \delta x) = \delta b$$

$$\delta x = -A^{-1}\delta A(x + \delta x) + A^{-1}\delta b$$

$$(I + A^{-1}\delta A)\delta x = A^{-1}(\delta b - \delta Ax)$$

假设 δA 足够小, 使 $I + A^{-1}\delta A$ 可逆

$$\delta x = (I + A^{-1}\delta A)^{-1}A^{-1}(\delta b - \delta Ax)$$

$$\|(I + A^{-1}\delta A)^{-1}\| \leq \frac{1}{1 - \|A^{-1}\delta A\|} \leq \frac{1}{1 - \|A^{-1}\|\|\delta A\|}$$

$$\|\delta x\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\delta A\|} (\|\delta b\| + \|\delta A\|\|x\|)$$

§2.5.2 误差分析: A 有小扰动 δA , b 有小扰动 δb

$$\|x\| \geq \|b\|/\|A\|$$

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\text{cond}(A)}{1 - \text{cond}(A) \frac{\|\delta A\|}{\|A\|}} \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right)$$

§2.5.2 误差分析

- $\text{cond}(A)$ 愈小, 由 A (或 b) 的相对误差引起解的相对误差就愈小;
- $\text{cond}(A)$ 愈大, 由 A (或 b) 的相对误差引起解的相对误差就有可能愈大. 所以, 量 $\text{cond}(A)$ 实际刻画了解对原始数据变化的敏感程度, 即刻画了方程组的病态程度.

§2.5.2 误差分析

- 对于一个确定的线性方程组，系数矩阵的条件数较小（接近 1）时，方程组是良态的；反之，条件数较大（ $\gg 1$ ）时，则称方程组是病态的；
- 条件数越大，则病态越严重；
- 条件数的值刻划了方程组病态的程度；
- 用一个稳定的方法去解一个良态方程组，必然得到精度很高的解。同样，用一个稳定的方法去解一个病态方程组，结果就可能很差。

§2.6 迭代法

为什么迭代法

- 直接法运算量 $\mathcal{O}(n^3)$, 随着矩阵规模的增大, 运算量也随之**快速增长**
- 对于大规模线性方程组, 特别是稀疏方程组, 当前的首选方法是**迭代方法**

迭代法基本思想

$Ax = b$, $A \in \mathbb{R}^{n \times n}$ 非奇异。

给定一个初始向量 $x^{(0)}$, 通过一定的迭代格式生成一个迭代序列 $\{x^{(k)}\}_{k=0}^{\infty}$, 使得

$$\lim_{k \rightarrow \infty} x^{(k)} = x^* \triangleq A^{-1}b$$

§2.6 迭代法

目前常用的两类迭代法

- **定常迭代法**: 如 Jacobi, Gauss-Seidel, SOR 等.
- **子空间迭代法**: 如 CG, MINRES, GMRES, BiCGStab 等.

我们主要学习**定常迭代法** (每一步的迭代格式不变)。将方程组 $Ax = b$ 改写成等价方程组

$$x = Bx + g$$

建立迭代格式

$$x^{(k+1)} = Bx^{(k)} + g, \quad k = 0, 1, 2, \dots$$

向量 $x^{(0)}$ 为初始预估解向量, B 称为迭代矩阵.

如果产生的序列 $\{x^{(k)}\}$ 对于任意初始向量 $x^{(0)}$ 均收敛于 x^* , 则迭代法是**收敛的**, 否则称为**发散**.

§2.6 迭代法: 收敛性

引理

设迭代序列 $\{x^{(k)}\}$ 收敛, 且 $\lim_{k \rightarrow \infty} x^{(k)} = x^*$, 则 x^* 一定是原方程组的解.

记

$$\epsilon^{(k)} = x^{(k)} - x^*, \quad k = 0, 1, 2, \dots,$$

称为第 k 步迭代的误差向量.

$$\begin{aligned}\epsilon^{(k+1)} &= x^{(k+1)} - x^* = B(x^{(k)} - x^*) = B\epsilon^{(k)} \\ \epsilon^{(k+1)} &= B^{k+1}\epsilon^{(0)} (k = 0, 1, 2, \dots)\end{aligned}$$

其中 $\epsilon^{(0)} = x^{(0)} - x^*$ 为初始误差向量.

考察收敛性, 就要研究 B 在什么条件下 $\epsilon^{(k)} \rightarrow 0 (k \rightarrow \infty)$, 即就要研究 B 满足什么条件时有

$$B^k \rightarrow 0 \quad (k \rightarrow \infty)$$

§2.6 迭代法: 收敛性

定理(迭代法基本定理) 下面三个命题是等价的.

- (I) 迭代法 $x^{(k+1)} = Bx^{(k)} + g$ 收敛;
- (II) $\rho(B) < 1$;
- (III) 至少存在一种矩阵的**从属范数** $\|\cdot\|$, 使得

$$\|B\| < 1$$

注: 迭代法的收敛性与收敛速度与迭代矩阵 B 有关, 而与右端向量 g 和初始向量 $x^{(0)}$ 无关.

一般来说, $\rho(B)$ 越小, 迭代方法的收敛速度越快

§2.6 迭代法: 收敛性

- 由于计算 $\rho(B)$ 通常比较复杂, 而 $\|B\|_1, \|B\|_\infty$ 相对比较容易计算, 因此在判别迭代方法收敛性时, 可以先验算一下迭代矩阵的 1-范数或 ∞ -范数是否小于 1 .
- 上述定理中 (III) 的结论是充分条件, 但不是必要条件, 因此判断一个迭代方法不收敛仍然需要使用基本收敛定理.

§2.6 迭代法: 误差估计

定理 设 x^* 为方程组 $Ax = b$ 的精确解. 若迭代法

$$x^{(k+1)} = Bx^{(k)} + g$$

的迭代矩阵 B 满足 $\|B\| < 1$, 其中 $\|\cdot\|$ 是某种算子范数, 则对于任意的初始向量 $x^{(0)}$ 与右端向量 g 迭代法收敛, 且有如下两个误差估计式:

- (i) $\|x^{(k)} - x^*\| \leq \frac{\|B\|}{1-\|B\|} \|x^{(k)} - x^{(k-1)}\|$
- (ii) $\|x^{(k+1)} - x^{(k)}\| \leq \|B\|^k \cdot \|x^{(1)} - x^{(0)}\|$
- (iii) $\|x^{(k)} - x^*\| \leq \frac{\|B\|^k}{1-\|B\|} \|x^{(1)} - x^{(0)}\|$

§2.6 迭代法: 误差估计

类似第一章的证明

证 $\rho(B) \leq \|B\| < 1$, 故对于任意的 $x^{(0)}$ 与 g 迭代收敛.

$$x^{(k)} - x^* = B(x^{(k-1)} - x^*)$$

$$\begin{aligned}\|x^{(k)} - x^*\| &= \|Bx^{(k-1)} - Bx^*\| \\ &= \|Bx^{(k-1)} - Bx^{(k)} + Bx^{(k)} - Bx^*\| \\ &\leq \|B\| \cdot \|x^{(k)} - x^{(k-1)}\| + \|B\| \cdot \|x^{(k)} - x^*\|\end{aligned}$$

得

$$\|x^{(k)} - x^*\| \leq \frac{\|B\|}{1 - \|B\|} \|x^{(k)} - x^{(k-1)}\|$$

§2.6 迭代法: 误差估计

$$\boldsymbol{x}^{(k+1)} - \boldsymbol{x}^{(k)} = \boldsymbol{B} \left(\boldsymbol{x}^{(k)} - \boldsymbol{x}^{(k-1)} \right)$$

$$\left\| \boldsymbol{x}^{(k+1)} - \boldsymbol{x}^{(k)} \right\| \leq \|\boldsymbol{B}\| \cdot \left\| \boldsymbol{x}^{(k)} - \boldsymbol{x}^{(k-1)} \right\|$$

反复利用 $\left\| \boldsymbol{x}^{(k+1)} - \boldsymbol{x}^{(k)} \right\| \leq \|\boldsymbol{B}\| \cdot \left\| \boldsymbol{x}^{(k)} - \boldsymbol{x}^{(k-1)} \right\|$ 得 (ii)、(iii) 成立.

§2.6 迭代法: 常用停止条件

1. $\|Ax_k - b\| < \varepsilon$;
2. $\|x_{k+1} - x_k\| < \varepsilon$;
3. 最大迭代步数, 满足此条件停止, 一般是迭代序列发散。

§2.6 迭代法: 基于矩阵分裂的迭代法

目前一类比较常用的定常迭代法是基于矩阵分裂的迭代法, 如 Jacobi 方法, Gauss-Seidel 方法, SOR (Successive Over-Relaxation, 超松弛) 方法等.

定义

矩阵分裂 Matrix Splitting: 设 $A \in \mathbb{R}^{n \times n}$ 非奇异, 我们称

$$A = M + N$$

为 A 的一个矩阵分裂, 其中 M 非奇异.

§2.6 迭代法: 基于矩阵分裂的迭代法

给定一个矩阵分裂, 则原方程组 $Ax = b$ 就等价于

$$Mx = Nx + b$$

于是我们就可以构造出以下的迭代格式

$$Mx^{(k+1)} = -Nx^{(k)} + b, \quad k = 0, 1, \dots,$$

或

$$x^{(k+1)} = -M^{-1}Nx^{(k)} + M^{-1}b \triangleq Bx^{(k)} + f, \quad k = 0, 1, \dots,$$

其中 $B \triangleq -M^{-1}N$ 为迭代矩阵.

选取不同的 M , 就得到不同的迭代方法.

§2.7.1 Jacobi 迭代法

将方程组 $Ax = b$ 的系数 A 分解成

$$A = L + D + U$$

其中 $D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$, L 和 U 分别是 A 的对角线下方元素和上方元素组成的严格下三角阵与严格上三角阵. 即

$$A = \begin{pmatrix} 0 & 0 & \cdots & 0 \\ a_{21} & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & 0 \end{pmatrix} + \begin{pmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{pmatrix} + \begin{pmatrix} 0 & a_{12} & \cdots & a_{1n} \\ 0 & 0 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix}$$

§2.7.1 Jacobi 迭代法

Jacobi 迭代法矩阵形式

若 $a_{ii} \neq 0 (i = 1, 2, \dots, n)$, 即 D 非奇异, 将方程组

$$Ax = b$$

取 $M = D, N = L + U$ 得

$$\begin{aligned} Dx &= -(L + U)x + b \\ x &= -D^{-1}(L + U)x + D^{-1}b \end{aligned}$$

建立迭代格式

$$x^{(k+1)} = -D^{-1}(L + U)x^{(k)} + D^{-1}b \quad (k = 0, 1, 2, \dots)$$

称为解方程组 $Ax = b$ 的 Jacobi 迭代法.

§2.7.1 Jacobi 迭代法

迭代矩阵 $B_J = -D^{-1}(L + U) = I - D^{-1}A$

$$B_J = \begin{pmatrix} 0 & -\frac{a_{12}}{a_{11}} & \cdots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & \cdots & -\frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & & \vdots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & \cdots & 0 \end{pmatrix}$$

§2.7.1 Jacobi 迭代法

若 $a_{ii} \neq 0 (i = 1, 2, \dots, n)$, 将方程组

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

转化为等价形式

$$\begin{cases} x_1 = -\frac{a_{12}}{a_{11}}x_2 - \frac{a_{13}}{a_{11}}x_3 - \cdots - \frac{a_{1n}}{a_{11}}x_n + \frac{b_1}{a_{11}} \\ x_2 = -\frac{a_{21}}{a_{22}}x_1 - \frac{a_{23}}{a_{22}}x_3 - \cdots - \frac{a_{2n}}{a_{22}}x_n + \frac{b_2}{a_{22}} \\ \vdots \\ x_n = -\frac{a_{n1}}{a_{nn}}x_1 - \frac{a_{n2}}{a_{nn}}x_2 - \cdots - \frac{a_{n,n-1}}{a_{nn}}x_{n-1} + \frac{b_n}{a_{nn}} \end{cases}$$

§2.7.1 Jacobi 迭代法

建立迭代格式 $k = 0, 1, \dots$

$$\begin{cases} x_1^{(k+1)} = -\frac{a_{12}}{a_{11}}x_2^{(k)} - \frac{a_{13}}{a_{11}}x_3^{(k)} - \dots - \frac{a_{1n}}{a_{11}}x_n^{(k)} + \frac{b_1}{a_{11}} \\ x_2^{(k+1)} = -\frac{a_{21}}{a_{22}}x_1^{(k)} - \frac{a_{23}}{a_{22}}x_3^{(k)} - \dots - \frac{a_{2n}}{a_{22}}x_n^{(k)} + \frac{b_2}{a_{22}} \\ \vdots \\ x_n^{(k+1)} = -\frac{a_{n1}}{a_{nn}}x_1^{(k)} - \frac{a_{n2}}{a_{nn}}x_2^{(k)} - \dots - \frac{a_{nn-1}}{a_{nn}}x_{n-1}^{(k)} + \frac{b_n}{a_{nn}} \end{cases}$$

称为解方程组 $Ax = b$ 的 Jacobi 迭代法.

Jacobi 迭代中 $x_i^{(k+1)}$ 的更新顺序与 i 无关, 因此非常适合并行计算.

§2.7.1 Jacobi 迭代法

Jacobi 迭代法的分量形式 (便于理解与编程实现)

若 $a_{ii} \neq 0$, 将方程组

$$\sum_{j=1}^n a_{ij}x_j = b_i \quad (i = 1, 2, \dots, n)$$

改写为

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}x_j \right) \quad (i = 1, 2, \dots, n)$$

建立迭代格式

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}x_j^{(k)} \right) \quad (i = 1, 2, \dots, n; k = 0, 1, 2, \dots)$$

§2.7.2 Gauss-Seidel(G-S) 迭代法

Gauss-Seidel 迭代法分量形式: $k = 0, 1, 2, \dots$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) \quad i = 1, 2, \dots, n$$

Gauss-Seidel 迭代法矩阵形式: 取 $M = L + D, N = U$, 将方程组 $Ax = b$, 改写成

$$\begin{aligned} (D + L)x &= -Ux + b \\ x &= -(D + L)^{-1}Ux + (D + L)^{-1}b \end{aligned}$$

建立迭代格式: $k = 0, 1, 2, \dots$

$$x^{(k+1)} = -(D + L)^{-1}Ux^{(k)} + (D + L)^{-1}b$$

称为解方程组 $Ax = b$ 的 Gauss-Seidel 迭代法.

迭代矩阵 $B_G = -(D + L)^{-1}U$

G-S 迭代充分利用了已经获得的最新数据, 有望获得更快的收敛速度

§2.7.3 超松弛迭代法 (SOR 方法)

基本思想

将 G-S 迭代法中的第 $k+1$ 步近似解与第 k 步近似解做一个加权平均, 从而给出一个更好的近似解.

由 Gauss-Seidel 迭代法得

$$\bar{x}_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

由此建立公式 $x_i^{(k+1)} = \omega \bar{x}_i^{(k+1)} + (1 - \omega) x_i^{(k)}$

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right)$$

称为松弛法, 其中 ω 为松弛因子. 为加速收敛, 取 $\omega > 1$, 这时 ω 称为超松弛因子. 当 $\omega = 1$ 时, 就是 Gauss-Seidel 迭代法.

§2.7.3 超松弛迭代法 (SOR 方法)

超松弛法的矩阵表示为

$$\boldsymbol{x}^{(k+1)} = (\boldsymbol{D} + \omega \boldsymbol{L})^{-1}[(1 - \omega)\boldsymbol{D} - \omega \boldsymbol{U}]\boldsymbol{x}^{(k)} + \omega(\boldsymbol{D} + \omega \boldsymbol{L})^{-1}\boldsymbol{b}$$

迭代矩阵 $\boldsymbol{B}_\omega = (\boldsymbol{D} + \omega \boldsymbol{L})^{-1}[(1 - \omega)\boldsymbol{D} - \omega \boldsymbol{U}]$

$$\boldsymbol{A} = \boldsymbol{L} + \boldsymbol{D} + \boldsymbol{U} + \frac{1}{\omega}\boldsymbol{D} - \frac{1}{\omega}\boldsymbol{D}$$

取 $\boldsymbol{M} = \boldsymbol{L} + \frac{1}{\omega}\boldsymbol{D}, \boldsymbol{N} = \boldsymbol{D} + \boldsymbol{U} - \frac{1}{\omega}\boldsymbol{D}$

$$(\boldsymbol{L} + \frac{1}{\omega}\boldsymbol{D})\boldsymbol{x} = -(\boldsymbol{D} + \boldsymbol{U} - \frac{1}{\omega}\boldsymbol{D})\boldsymbol{x} + \boldsymbol{b}$$

$$\boldsymbol{x}^{(k+1)} = (\boldsymbol{D} + \omega \boldsymbol{L})^{-1}[(1 - \omega)\boldsymbol{D} - \omega \boldsymbol{U}]\boldsymbol{x}^{(k)} + \omega(\boldsymbol{D} + \omega \boldsymbol{L})^{-1}\boldsymbol{b}$$

迭代矩阵 $\boldsymbol{B}_\omega = (\boldsymbol{D} + \omega \boldsymbol{L})^{-1}[(1 - \omega)\boldsymbol{D} - \omega \boldsymbol{U}]$

SOR 方法最大的优点是引入了松弛参数 ω , 增加了算法的自由度, 同时通过选取适当的 ω 可以大大提高方法的收敛速度. 如何确定 SOR 的最优松弛因子是一件非常困难的事!

§2.8 迭代法收敛性判定

- Jacobi 迭代收敛的**充要**条件: $\rho(B_J) < 1$
- G-S 迭代收敛的**充要**条件: $\rho(B_G) < 1$
- SOR 迭代收敛的**充要**条件: $\rho(B_\omega) < 1$

- Jacobi 迭代收敛的**充分**条件: $\|B_J\| < 1$
- G-S 迭代收敛的**充分**条件: $\|B_G\| < 1$
- SOR 迭代收敛的**充分**条件: $\|B_\omega\| < 1$

§2.8 迭代法收敛性判定

定义 称方阵 $A = (a_{ij})_{nn}$ 为严格对角占优矩阵, 如果

$$\sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| < |a_{ii}| \quad (i = 1, 2, \dots, n)$$

定义 称方阵 $A = (a_{ij})_{nn}$ 为弱对角占优的矩阵, 如果

$$\sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \leq |a_{ii}| \quad (i = 1, 2, \dots, n)$$

上式至少有一个不等式严格成立

定理

若线性方程组 $Ax = b$ 的系数方阵 A 是严格**对角占优矩阵**, 则 Jacobi 迭代法和 Gauss-Seidel 迭代法都是收敛的.

§2.8 迭代法收敛性判定

Jacobi 迭代矩阵

$$G_J = I - D^{-1}A = \begin{pmatrix} 0 & -\frac{a_{12}}{a_{11}} & \cdots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & \cdots & -\frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & & \vdots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & \cdots & 0 \end{pmatrix}$$

由于 A 是严格对角占优矩阵, 即

$$\sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| < |a_{ii}| \quad (i = 1, 2, \cdots, n)$$

故

$$\|G_J\|_{\infty} = \max_{1 \leq i \leq n} \sum_{\substack{j=1 \\ j \neq i}}^n \left| \frac{a_{ij}}{a_{ii}} \right| < 1$$

从而 Jacobi 迭代收敛

§2.8 迭代法收敛性判定

定理

设 $A \in \mathbb{R}^{n \times n}$ 对称且 D 正定 (或称对角元 $a_{ii} > 0$), 则 Jacobi 收敛的**充要条件**是 $2D - A$ 正定.

定理

设 $A \in \mathbb{R}^{n \times n}$ 对称且 D 正定 (或称对角元 $a_{ii} > 0$), 则 G-S 收敛的**充要条件**是 A 正定.

§2.8 迭代法收敛性判定:SOR

定理

SOR 方法收敛的必要条件是 $0 < \omega < 2$.

定理

若线性方程组 $Ax = b$ 的系数矩阵 A 为严格对角占优矩阵, 则当 $0 < \omega \leq 1$ 时, SOR 方法收敛.

定理

若线性方程组 $Ax = b$ 的系数矩阵 A 为对称正定阵, 则 SOR 迭代方法收敛的充要条件是 $0 < \omega < 2$.

§2.9 特定迭代法的例子

例 对方程组

$$\begin{cases} x_1 + 2x_2 - 2x_3 = 1 \\ x_1 + x_2 + x_3 = 2 \\ 2x_1 + 2x_2 + x_3 = 3 \end{cases}$$

分别讨论用 Jacobi 迭代法和 Gauss-Seidel 迭代法求解的收敛性.

解 系数矩阵

$$\begin{aligned} \mathbf{A} &= \begin{bmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \end{bmatrix} + \begin{bmatrix} 0 & & \\ 1 & 0 & \\ 2 & 2 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 2 & -2 \\ & 0 & 1 \\ & & 0 \end{bmatrix} \\ &= \mathbf{D} + \mathbf{L} + \mathbf{U} \end{aligned}$$

§2.9 迭代法收敛性判定的例子

Jacobi 迭代法的迭代矩阵为

$$\begin{aligned} B_J &= I - D^{-1}A = \begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \end{bmatrix} - \begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 0 & -2 & 2 \\ -1 & 0 & -1 \\ -2 & -2 & 0 \end{bmatrix} \end{aligned}$$

B_J 的特征方程为

$$|\lambda I - B_J| = \begin{vmatrix} \lambda & 2 & -2 \\ 1 & \lambda & 1 \\ 2 & 2 & \lambda \end{vmatrix} = \lambda^3 = 0$$

因此有 $\lambda_1 = \lambda_2 = \lambda_3 = 0$, 即 $\rho(B_J) = 0 < 1$, 所以 Jacobi 迭代法收敛.

§2.9 迭代法收敛性判定的例子

Gauss-Seidel 迭代法的迭代矩阵为

$$\begin{aligned} B_G = -(D + L)^{-1}U &= - \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -2 & 1 \end{bmatrix} \begin{bmatrix} 0 & 2 & -2 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 0 & -2 & 2 \\ 0 & 2 & -3 \\ 0 & 0 & 2 \end{bmatrix} \end{aligned}$$

B_G 的特征方程为

$$|\lambda I - B_G| = \begin{vmatrix} \lambda & 2 & -2 \\ 0 & \lambda - 2 & 3 \\ 0 & 0 & \lambda - 2 \end{vmatrix} = \lambda(\lambda - 2)^2 = 0$$

因此有 $\lambda_1 = 0, \lambda_2 = \lambda_3 = 2$, 即 $\rho(B_G) = 2 > 1$, 所以 Gauss-Seidel 迭代法发散.

§2.10 梯度法

假设 $A \in \mathbb{R}^{n \times n}$ 为对称正定矩阵.
把线性方程组

$$Ax = b$$

的惟一解 x^* 看作是使自变量为 x (向量) 的某一个二次函数 $f(x)$ 取最小值的点.
建立求使 $f(x)$ 取最小值的点 x^* 的迭代法, 从而求出的 $Ax = b$ 的解 x^* .

§2.10 梯度法

定义 对于实向量的 x 的二次函数

$$f(x) = \frac{1}{2}(\mathbf{A}x, x) - (\mathbf{b}, x) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{j=1}^n b_j x_j$$

$$f(x) = \frac{1}{2} \sum_{i=1}^n (a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{im}x_m + \cdots + a_{in}x_n) x_i - \sum_{j=1}^n b_j x_j$$

对 $m = 1, 2, \dots, n$

$$\frac{\partial f}{\partial x_m} = \frac{1}{2} \left(\sum_{i=1}^n a_{im} x_i + \sum_{j=1}^n a_{mj} x_j \right) - b_m = - \left(b_m - \sum_{j=1}^n a_{mj} x_j \right)$$

$f(x)$ 在点 x 的梯度向量为

$$\text{grad } f(x) = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right]^T = -(\mathbf{b} - \mathbf{A}x) = -\mathbf{r}$$

§2.10 梯度法: 等价性问题及几何意义

设 x^* 是 $Ax = b$ 的解, 由于

$$\begin{aligned} f(x^*) &= \frac{1}{2}(Ax^*, x^*) - (b, x^*) = \frac{1}{2}(Ax^*, x^*) - (Ax^*, x^*) \\ &= -\frac{1}{2}(Ax^*, x^*) \end{aligned}$$

$$\begin{aligned} f(x) - f(x^*) &= \frac{1}{2}(Ax, x) - (b, x) + \frac{1}{2}(Ax^*, x^*) \\ &= \frac{1}{2}[(Ax, x) - 2(Ax^*, x) + (Ax^*, x^*)] \\ &= \frac{1}{2}(A(x - x^*), x - x^*) \geq 0 \end{aligned}$$

所以 $f(x) \geq f(x^*)$ x^* 是使 $f(x)$ 取最小值的点.

反之, 若 x^* 是使 $f(x)$ 取最小值的点, 则

$$\left[\frac{\partial f}{\partial x_m} \right]_{x=x^*} = 0, \quad m = 1, 2, \dots, n$$

则得 $Ax^* = b$. ($f(x)$ 有唯一极小值—最小值, 它是 $f(x)$ 在 $Ax = b$ 的解 x^* 处的值)

§2.10 梯度法: 等价性问题及几何意义

定理 (等价性定理) $x^* \in \mathbb{R}^n$ 为 $Ax = b$ 的解的充分且必要条件是 x^* 使定义的二次函数 $f(x)$ 取最小值, 即

$$\min_{x \in \mathbb{R}^n} f(x) = f(x^*)$$

几何意义

$$f(x) - f(x^*) = \frac{1}{2} (A(x - x^*), x - x^*) = \frac{1}{2} (x - x^*)^T A (x - x^*)$$

方程 $f(x) = C$, 即为方程 $\frac{1}{2} (x - x^*)^T A (x - x^*) = C - f(x^*)$ 表示 n 维椭球面, 以 x^* 为中心 ($C > f(x^*)$).

线性方程组 $Ax = b$ 的求解问题等价于求一簇 n 维椭球面的公共中心问题.

§2.10 梯度法: 迭代法的建立

思想: 构造向量序列 $\{x^{(k)}\}$, 使

(i) $f(x^{(k+1)}) < f(x^{(k)}) < \dots < f(x^{(1)}) < f(x^{(0)})$

(ii) 当 $k \rightarrow \infty$ 时, $f(x^{(k)}) \rightarrow f(x^*)$

这与要求 $x^{(k)} \rightarrow x^* (k \rightarrow \infty)$ 是一致的.

具体方法: 由第 k 个近似 $x^{(k)}$ 构造下一个近似 $x^{(k+1)}$, 首先选定一个向量 p_k 作为方向, 要在直线 $x = x^{(k)} + tp_k$ (t 为参数) 上找一个使 $f(x)$ 为极小的点 $x^{(k+1)}$, 即确定参数 t 使 $f(x^{(k)} + tp_k)$ 为极小.

§2.10 梯度法

单变量 t 的二次函数

$$\varphi(t) = f(\mathbf{x}^{(k)} + t\mathbf{p}_k) = \frac{1}{2}t^2 (\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) - t(\mathbf{b} - \mathbf{A}\mathbf{x}^{(k)}, \mathbf{p}_k) + f(\mathbf{x}^{(k)})$$

令 $\varphi'(t) = t(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) - (\mathbf{r}^{(k)}, \mathbf{p}_k) = 0$ 得 $t = \frac{(\mathbf{r}^{(k)}, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)}$ 且这时有

$\varphi''(t) = (\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) \neq 0$, 从而得极小 $f(\mathbf{x}^{(k+1)})$. 其中

$$\begin{cases} \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}_k \\ \alpha_k = \frac{(\mathbf{r}^{(k)}, \mathbf{p}_k)}{(\mathbf{A}\mathbf{p}_k, \mathbf{p}_k)} \end{cases}$$

$$\mathbf{r}^{(k+1)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k+1)} = \mathbf{b} - \mathbf{A}(\mathbf{x}^{(k)} + \alpha_k \mathbf{p}_k) = \mathbf{r}^{(k)} - \alpha_k \mathbf{A}\mathbf{p}_k$$

$$(\mathbf{r}^{(k+1)}, \mathbf{p}_k) = (\mathbf{r}^{(k)}, \mathbf{p}_k) - \alpha_k (\mathbf{A}\mathbf{p}_k, \mathbf{p}_k) = 0$$

$\mathbf{r}^{(k+1)}$ 与 \mathbf{p}_k 正交.

(方向向量 \mathbf{p}_k 的选取决定着寻找这簇 n 维椭球面的公共中心的速度, 其取法不同, 效率不同)

§2.10 梯度法: 最速下降法

在 n 维空间定义的二次函数 $f(\boldsymbol{x})$ 在点 $\boldsymbol{x}^{(k)}$ 的改变率最大的方向是 $f(\boldsymbol{x})$ 在点 $\boldsymbol{x}^{(k)}$ 的梯度

$$\text{grad } f(\boldsymbol{x})|_{\boldsymbol{x}=\boldsymbol{x}^{(k)}} = -\boldsymbol{r}^{(k)}$$

因此沿方向 $\boldsymbol{r}^{(k)}$ 函数 $f(\boldsymbol{x})$ 瞬时下降的最快, 所以取这个方向为 \boldsymbol{p}_k 而得到新的近似 $\boldsymbol{x}^{(k+1)}$ 的方法就叫最速下降法.

$$\begin{cases} \boldsymbol{x}^{(k+1)} &= \boldsymbol{x}^{(k)} + \alpha_k \boldsymbol{r}^{(k)} \\ \alpha_k &= \frac{(\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)})}{(\boldsymbol{A}\boldsymbol{r}^{(k)}, \boldsymbol{r}^{(k)})} \end{cases} \quad k = 0, 1, 2, \dots$$

只要 $\boldsymbol{r}^{(k)} \neq \mathbf{0}$, 最速下降法就继续下去, 这里有 $(\boldsymbol{r}^{(k+1)}, \boldsymbol{r}^{(k)}) = 0$.

§2.10 梯度法: 最速下降法

(i) 给定 $\mathbf{x}^{(0)} \in \mathbb{R}^n$, 设 $\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}$,

(ii) 对 $k = 0, 1, \dots$ 计算



$$\alpha_k = \frac{(\mathbf{r}^{(k)}, \mathbf{r}^{(k)})}{(\mathbf{r}^{(k)}, \mathbf{A}\mathbf{r}^{(k)})}$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{r}^{(k)}$$

$$\mathbf{r}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k \mathbf{A}\mathbf{r}^{(k)}$$

直到收敛

注 常用的 $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| < \varepsilon$ 或者 $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq \varepsilon$



§2.10 梯度法: 共轭梯度法

求解 $Ax = b$ 的最速下降法的最速下降方向, 即

$$r^{(k)} = -\operatorname{grad} f(x^{(k)})$$

具有局部性质, 在 $x^{(k)}$ 附近 $f(x)$ 沿 $r^{(k)}$ 下降最快. 但总体看, 这个方向未必是函数下降最理想的方向. 下面介绍更合理地选择方向 p_k 的方法, 这种方法只要经过有限步 ($\leq n$) 就能找到 n 维椭球面簇的公共中心 x^* 的一种迭代法, 即共轭梯度法, 它是具有迭代形式的精确解法.

定义 $A \in \mathbb{R}^{n \times n}$ 为对称正定矩阵, $p, l \in \mathbb{R}^n$, 如果 $(p, Al) = 0$, 则称 p 与 l 为 A -正交或 A -共轭.

§2.10 梯度法: 共轭梯度法

第 k 步选择的方向 $\mathbf{p}^{(k)}$, $f(\mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)})$ 取最小值时

$$\alpha_k = \frac{\mathbf{p}^{(k)T} \mathbf{r}^{(k)}}{\mathbf{p}^{(k)T} \mathbf{A} \mathbf{p}^{(k)}}, \quad \mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(k)}, \quad (7)$$

和

$$\mathbf{r}^{(k+1)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k \mathbf{A} \mathbf{p}^{(k)}. \quad (8)$$

则

$$\left(\mathbf{p}^{(k)}\right)^T \mathbf{r}^{(k+1)} = \left(\mathbf{p}^{(k)}\right)^T (\mathbf{r}^{(k)} - \alpha_k \mathbf{A} \mathbf{p}^{(k)}) = 0. \quad (9)$$

梯度法的选择: $\mathbf{p}^{(k)} = \mathbf{r}^{(k)}$ 满足

$$\left(\mathbf{p}^{(k)}\right)^T \mathbf{p}^{(k+1)} = 0$$

新的策略: 选择新的方向 $\mathbf{p}^{(k+1)}$ 满足

$$\left(\mathbf{A} \mathbf{p}^{(j)}\right)^T \mathbf{p}^{(k+1)} = 0, \quad j = 0, \dots, k \quad (10)$$

§2.10 梯度法: 共轭梯度法

假设 $k \geq 1$

$$\left(\mathbf{A}\mathbf{p}^{(i)}\right)^T \mathbf{p}^{(j)} = 0, \quad \forall i, j = 0, \dots, k, i \neq j \quad (11)$$

称(11) 为 \mathbf{A} -正交
同样假设

$$\left(\mathbf{p}^{(j)}\right)^T \mathbf{r}^{(k)} = 0, \quad j = 0, 1, \dots, k-1, \quad k \geq 1; \quad (12)$$

称

$$\left(\mathbf{p}^{(j)}\right)^T \mathbf{r}^{(k+1)} = 0, \quad j = 0, \dots, k, \quad k \geq 0. \quad (13)$$

用归纳法证明 (13). 对于 $k = 0$, $\mathbf{r}^{(1)} = \mathbf{r}^{(0)} - \alpha_0 \mathbf{A}\mathbf{r}^{(0)}$, 则 $\left(\mathbf{p}^{(0)}\right)^T \mathbf{r}^{(1)} = 0$,

$$\alpha_0 = \frac{\left(\mathbf{p}^{(0)}\right)^T \mathbf{r}^{(0)}}{\left(\mathbf{p}^{(0)}\right)^T \mathbf{A}\mathbf{p}^{(0)}},$$

§2.10 梯度法: 共轭梯度法

建设前面 k 步成立, $k+1$ 时

$$\left(\mathbf{p}^{(j)}\right)^T \mathbf{r}^{(k+1)} = \left(\mathbf{p}^{(j)}\right)^T \mathbf{r}^{(k)} - \alpha_k \left(\mathbf{A}\mathbf{p}^{(j)}\right)^T \mathbf{p}^{(k)} = 0.$$

下来使用有效的方法确定方向 $\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(k)}$ 满足 A -正交。
初始化 $\mathbf{p}^{(0)} = \mathbf{r}^{(0)}$, 对 $k \geq 0$, 选择方向

$$\mathbf{p}^{(k+1)} = \mathbf{r}^{(k+1)} - \beta_k \mathbf{p}^{(k)}, \quad k = 0, 1, \dots$$

在(10)中取 $j = k$ 得

$$\beta_k = \frac{\left(\mathbf{A}\mathbf{p}^{(k)}\right)^T \mathbf{r}^{(k+1)}}{\left(\mathbf{A}\mathbf{p}^{(k)}\right)^T \mathbf{p}^{(k)}}, \quad k = 0, 1, \dots$$

此时(10)中 $j = k$ 是成立的.

§2.10 梯度法: 共轭梯度法

$$\left(\mathbf{A}\mathbf{p}^{(j)}\right)^T \mathbf{p}^{(k+1)} = \left(\mathbf{A}\mathbf{p}^{(j)}\right)^T \mathbf{r}^{(k+1)} - \beta_k \left(\mathbf{A}\mathbf{p}^{(j)}\right)^T \mathbf{p}^{(k)}$$

下面来验证

$$\left(\mathbf{A}\mathbf{p}^{(j)}\right)^T \mathbf{r}^{(k+1)} = 0, \quad j = 0, 1, \dots, k-1. \quad (14)$$

设

$$V_k = \text{span}\{\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(k)}\},$$

选择 $\mathbf{p}^{(0)} = \mathbf{r}^{(0)}$ 则

$$V_k = \text{span}\{\mathbf{r}^{(0)}, \mathbf{r}^{(1)}, \dots, \mathbf{r}^{(k)}\},$$

$$\mathbf{p}^{(k+1)} = \mathbf{r}^{(k+1)} - \beta_k \mathbf{p}^{(k)} \in \text{span}\{\mathbf{r}^{(0)}, \mathbf{r}^{(1)}, \dots, \mathbf{r}^{(k+1)}\}$$

$$\mathbf{r}^{(k+1)} = \mathbf{p}^{(k+1)} + \beta_k \mathbf{p}^{(k)} \in \text{span}\{\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(k+1)}\}$$

$$\mathbf{A}\mathbf{p}^{(k)} = \left(\mathbf{r}^{(k)} - \mathbf{r}^{(k+1)}\right) / \alpha_k \in V_{k+1}.$$

由于 $\mathbf{r}^{(k+1)} \perp V_k$, 则(14)成立。

§2.10 梯度法: 共轭梯度法

共轭梯度法 (算法)

(i) 任取初值 $\mathbf{x}^{(0)} \in \mathbb{R}^n$

(ii) $\mathbf{p}^{(0)} = \mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}$

(iii) 对于 $k = 0, 1, 2, \dots$,

$$\alpha_k = \frac{(\mathbf{r}^{(k)}, \mathbf{p}^{(k)})}{(\mathbf{A}\mathbf{p}^{(k)}, \mathbf{p}^{(k)})}$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}$$

$$\mathbf{r}^{(k+1)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k \mathbf{A}\mathbf{p}^{(k)}$$

$$\beta_k = -\frac{(\mathbf{r}^{(k+1)}, \mathbf{A}\mathbf{p}^{(k)})}{(\mathbf{p}^{(k)}, \mathbf{A}\mathbf{p}^{(k)})}$$

$$\mathbf{p}^{(k+1)} = \mathbf{r}^{(k+1)} + \beta_k \mathbf{p}^{(k)}$$


直到收敛

§2.10 梯度法: 共轭梯度法

定理 设 $\{r^{(k)}\}, \{p_k\}$ 分别为由共轭梯度法产生的剩余向量序列和共轭方向序列, 则 $\{r^{(k)}\}$ 构成一个正交系, $\{p_k\}$ 构成一个 A -正交系, 即

$$(r^{(i)}, r^{(j)}) = 0, \quad i \neq j$$

$$(p_i, Ap_j) = 0, \quad i \neq j$$



(b) 虚线为共轭梯度法, 实线为梯度法

§2.10 梯度法: 共轭梯度法

定理 共轭梯度法 CG **最多迭代 n 次** 就能得到方程组 $Ax = b$ 的精确解 x^* .

证 方向 $p^{(0)}, p^{(1)}, \dots, p^{(n-1)}$ 是 \mathbb{R}^n 的 A -正交基。

$r^{(k)}$ 与空间

$$V_{k-1} = \text{span}\{p^{(0)}, p^{(1)}, \dots, p^{(k-1)}\}$$

正交。

$r^{(n)} \perp V_{n-1} = \mathbb{R}^n$ 则 $r^{(n)} = 0$ 隐含 $x^{(n)} = x$.

§2.10 梯度法: 例

例 用共轭梯度法 (CG 方法) 解方程组

$$\begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 5 \\ 5 \end{pmatrix}$$

解 系数矩阵为对称正定阵, 取初值 $\mathbf{x}^{(0)} = (0, 0)^T$;

$$\mathbf{p}^{(0)} = \mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)} = (5, 5)^T$$

$$\alpha_0 = \frac{(\mathbf{r}^{(0)}, \mathbf{r}^{(0)})}{(\mathbf{A}\mathbf{p}^{(0)}, \mathbf{p}^{(0)})} = \frac{2}{7}$$

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \alpha_0 \mathbf{p}^{(0)} = (10/7, 10/7)^T$$

$$\mathbf{r}^{(1)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(1)} = \mathbf{r}^{(0)} - \alpha_0 \mathbf{A}\mathbf{p}^{(0)} = (-5/7, 5/7)^T$$

$$\beta_0 = -\frac{(\mathbf{r}^{(1)}, \mathbf{A}\mathbf{p}^{(0)})}{(\mathbf{A}\mathbf{p}^{(0)}, \mathbf{p}^{(0)})} = \frac{(\mathbf{r}^{(1)}, \mathbf{r}^{(1)})}{(\mathbf{r}^{(0)}, \mathbf{r}^{(0)})} = \frac{1}{49}$$

§2.10 梯度法: 例

$$\mathbf{p}^{(1)} = \mathbf{r}^{(1)} + \beta_0 \mathbf{p}^{(0)} = (-30/49, 40/49)^T$$

$$\alpha_1 = \frac{(\mathbf{r}^{(1)}, \mathbf{p}^{(1)})}{(\mathbf{A}\mathbf{p}^{(1)}, \mathbf{p}^{(1)})} = \frac{7}{10}$$

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \alpha_1 \mathbf{p}^{(1)} = (1, 2)^T$$

两步得精确解.